Báo cáo Chuyên sâu về Phân đoạn Ngữ nghĩa: Các Phương pháp SOTA và Xu hướng Chuyển dịch sang Mô hình Nền tảng (2024-2026)

Lĩnh vực phân đoạn ngữ nghĩa (Semantic Segmentation) đã trải qua một cuộc cách mạng sâu sắc, chuyển dịch từ các phương pháp xử lý ảnh truyền thống dựa trên đặc trưng thủ công sang kỷ nguyên của học sâu (Deep Learning) và gần đây nhất là các mô hình nền tảng (Foundation Models) có khả năng hiểu thị giác quy mô lớn. Phân đoạn ngữ nghĩa không chỉ đơn thuần là việc phân loại hình ảnh mà là quá trình gán nhãn cho từng pixel đơn lẻ, cho phép máy tính hiểu được "cái gì nằm ở đâu" với độ chính xác ở mức độ vi mô.[1] Khả năng này đóng vai trò là nền tảng cho các ứng dụng thực tế quan trọng, từ hệ thống tự lái yêu cầu phân biệt bề mặt đường và vỉa hè, đến phân tích hình ảnh y khoa để xác định ranh giới khối u, và viễn thám để lập bản đồ lớp phủ mặt đất một cách chi tiết.[3]

Sự Tiến hóa của các Kiến trúc Học sâu trong Phân đoạn Ngữ nghĩa

Lịch sử phát triển của các kiến trúc mạng thần kinh trong phân đoạn ngữ nghĩa có thể được chia thành ba giai đoạn chính: giai đoạn thống trị của mạng tích chập (CNN), giai đoạn trỗi dậy của Transformer và giai đoạn hiện nay là sự hội tụ của các mô hình nền tảng đa phương thức.

Kỷ nguyên Mạng Tích chập (CNN) và các Cơ chế Context

Sự ra đời của Mạng tích chập hoàn toàn (Fully Convolutional Network - FCN) đã đánh dấu một bước ngoặt quan trọng, thay thế các lớp kết nối đầy đủ bằng các lớp tích chập để cho phép dự đoán pixel-wise đầu cuối.[3] Tuy nhiên, các kiến trúc CNN sơ khai thường gặp khó khăn trong việc nắm bắt bối cảnh (context) đa quy mô và duy trì độ phân giải không gian.

Để giải quyết vấn đề này, kiến trúc DeepLabV3+ đã giới thiệu mô-đun Atrous Spatial Pyramid Pooling (ASPP), sử dụng các phép tích chập lỗ hổng (atrous convolution) với các tỷ lệ giãn nở (dilation rates) khác nhau.[6] Cơ chế này cho phép mô hình mở rộng trường thụ cảm (receptive field) mà không làm mất đi độ phân giải của bản đồ đặc trưng (feature map), giúp nắm bắt bối cảnh hiệu quả hơn cho các đối tượng có kích thước khác nhau.[6] DeepLabV3+ tích hợp cấu trúc encoder-decoder để tinh chỉnh các ranh giới đối tượng, đạt được hiệu suất vượt trội trên các bộ dữ liệu như Cityscapes với chỉ số $mIoU$ đạt 89.3%.[6]

Một hướng đi khác là duy trì độ phân giải cao trong suốt mạng lưới, điển hình là kiến trúc HRNet

(High-Resolution Network). Khác với các mô hình truyền thống thường nén ảnh thành các biểu diễn độ phân giải thấp rồi khôi phục lại, HRNet duy trì các nhánh con độ phân giải cao song song với các nhánh độ phân giải thấp.[6] Sự tương tác liên tục giữa các nhánh này cho phép mô hình giữ lại các chi tiết không gian tinh vi, điều cực kỳ quan trọng trong việc phân đoạn các ranh giới phức tạp trong cảnh quan đô thị hoặc hình ảnh viễn thám.[6] Khi kết hợp với mô-đun Object-Contextual Representation (OCR), HRNet có khả năng tăng cường mối quan hệ giữa các pixel và các lớp đối tượng tương ứng, đẩy giới hạn độ chính xác lên mức cao mới.[6]

Sự trỗi dậy của Vision Transformers (ViTs)

Thành công của kiến trúc Transformer trong xử lý ngôn ngữ tự nhiên đã thúc đẩy sự chuyển dịch mạnh mẽ trong thị giác máy tính. Khác với CNN dựa trên các toán tử cục bộ, Vision Transformers (ViTs) sử dụng cơ chế tự chú ý (self-attention) để mô hình hóa các phụ thuộc tầm xa (long-range dependencies) trên toàn bộ hình ảnh.[2]

Các mô hình như SegFormer và Mask2Former đã thiết lập các tiêu chuẩn mới về hiệu quả và độ chính xác. SegFormer sử dụng một encoder transformer phân cấp để tạo ra các đặc trưng đa quy mô mà không cần mã hóa vị trí (positional encoding) phức tạp, kết hợp với một decoder MLP đơn giản nhưng hiệu quả.[9] Trong khi đó, Mask2Former đã hợp nhất các nhiệm vụ phân đoạn ngữ nghĩa, phân đoạn thực thể (instance segmentation) và phân đoạn toàn cảnh (panoptic segmentation) bằng cách coi chúng là một bài toán phân loại mặt nạ (mask classification).[9] Với cơ chế chú ý mặt nạ (masked attention), Mask2Former tập trung vào các vùng liên quan, giúp hội tụ nhanh hơn và đạt hiệu suất SOTA trên nhiều bộ dữ liệu, bao gồm điểm số Panoptic Quality (PQ) là 57.8 trên COCO.[9]

Loại Kiến trúc	**Cơ chế Cốt lõi**	**Ưu điểm Chính**	**Benchmark tiêu biểu (mIoU)**
CNN-based	Atrous Conv / ASPP	Đặc trưng cục bộ, Context đa quy mô	89.3 (Cityscapes) [6]
HR-CNN	Nhánh đa phân giải song song	Chi tiết không gian, Độ chính xác biên	84.5 (Cityscapes) [9]
Transformer	Self-Attention	Phụ thuộc tầm xa, Context toàn cục	51.8 (ADE20K) [9]
Foundation	Deformable Conv / Unified	Quy mô lớn, Khả năng tổng quát hóa	62.9 (ADE20K) [13]

Các Mô hình Nền tảng và Phân đoạn Mọi thứ (Segment Anything)

Một xu hướng nổi bật nhất trong giai đoạn 2024-2026 là sự xuất hiện của các mô hình nền tảng (Foundation Models), vốn được huấn luyện trên các tập dữ liệu khổng lồ để có khả năng thích ứng với nhiều nhiệm vụ khác nhau thông qua các câu lệnh (prompts) mà không cần huấn luyện lại từ đầu.[14]

Hệ sinh thái Segment Anything Model (SAM)

Sự ra đời của Segment Anything Model (SAM) bởi Meta AI đã thay đổi hoàn toàn tư duy về phân đoạn thực thể. SAM được huấn luyện trên tập dữ liệu SA-1B với hơn 1 tỷ mặt nạ, cho phép nó phân đoạn bất kỳ đối tượng nào dựa trên các gợi ý như điểm, hộp bao hoặc văn bản.[14] Tuy nhiên, phiên bản SAM đầu tiên chủ yếu tập trung vào hình ảnh tĩnh.

Sự phát triển của SAM 2 đã mở rộng khả năng này sang video bằng cách tích hợp kiến trúc bộ nhớ luồng (streaming memory).[14] Cơ chế này cho phép mô hình duy trì bối cảnh không gian và thời gian, giúp theo dõi và phân đoạn đối tượng nhất quán qua các khung hình video.[14] SAM 2 giải quyết các thách thức về sự thay đổi góc nhìn và vật cản bằng cách điều kiện hóa các nhúng (embeddings) hiện tại dựa trên bộ nhớ quá khứ.[14]

Bước tiến mới nhất được ghi nhận là SAM 3, dự kiến sẽ trở thành tiêu chuẩn mới trong năm 2025-2026. SAM 3 giới thiệu khái niệm Phân đoạn Khái niệm có thể gợi ý (Promptable Concept Segmentation - PCS). Thay vì chỉ phân đoạn các thực thể đơn lẻ, SAM 3 có khả năng phát hiện, phân đoạn và theo dõi tất cả các trường hợp của một khái niệm thị giác (ví dụ: "mọi chiếc xe màu đỏ") dựa trên văn bản hoặc hình ảnh ví dụ.[19] Kiến trúc của SAM 3 được phân tách thành một detector (bộ phát hiện) và một tracker (bộ theo dõi) chia sẻ chung một Perception Encoder (PE).[19] Một đổi mới quan trọng là "Presence Head", sử dụng một token toàn cục để dự đoán sự hiện diện của khái niệm trước khi thực hiện định vị, giúp giảm thiểu xung đột giữa nhận diện và khu trú đối tượng.[19]

Mô hình InternImage-H và Quy mô lớn

InternImage-H đại diện cho đỉnh cao của các mô hình nền tảng dựa trên CNN quy mô lớn với hơn 3 tỷ tham số.[13] Khác với các ViT truyền thống, InternImage sử dụng Deformable Convolution v3 (DCNv3) làm toán tử cốt lõi, cho phép tổng hợp không gian thích ứng và nắm bắt các phụ thuộc tầm xa tương tự như transformer nhưng vẫn giữ được các ưu điểm về hiệu năng và định kiến quy nạp (inductive bias) của CNN.[8] Mô hình này đã đạt kỷ lục thế giới với $62.9\ mIoU$ trên bộ dữ liệu ADE20K.[8]

Sự kết hợp giữa quy mô tham số khổng lồ và các toán tử linh hoạt cho phép các mô hình như InternImage-H hoặc BEiT-3 vượt qua các rào cản về độ chính xác mà các kiến trúc nhỏ hơn

không thể chạm tới. BEiT-3 xử lý hình ảnh như một "ngôn ngữ ngoại quốc", sử dụng khung học tập mặt nạ thống nhất cho cả thị giác và ngôn ngữ, đạt $62.8\ mIoU$ trên ADE20K.[24]

Phân đoạn Ngữ nghĩa Từ vựng Mở (Open-Vocabulary Semantic Segmentation - OVSS)

Một hạn chế lớn của các mô hình phân đoạn truyền thống là chúng chỉ có thể nhận diện các lớp đối tượng đã xuất hiện trong tập huấn luyện (Closed-world). Phân đoạn ngữ nghĩa từ vựng mở (OVSS) hướng tới việc phân đoạn bất kỳ khái niệm thị giác nào dựa trên ngôn ngữ tự nhiên, ngay cả những lớp chưa từng được dán nhãn pixel-wise.[1]

Tận dụng các mô hình Ngôn ngữ-Thị giác (VLMs)

Hầu hết các phương pháp OVSS hiện đại đều tận dụng khả năng của CLIP (Contrastive Language-Image Pre-training). CLIP được huấn luyện trên hàng trăm triệu cặp ảnh-văn bản từ internet, tạo ra một không gian nhúng chung nơi các đặc trưng hình ảnh và văn bản có thể được so sánh trực tiếp.[1]

Các phương pháp không cần huấn luyện (training-free) đang trở nên phổ biến vì chúng giúp tránh được chi phí dán nhãn pixel đắt đỏ.[1] PixelCLIP là một ví dụ điển hình, nó thích ứng encoder hình ảnh của CLIP cho các nhiệm vụ mức độ pixel bằng cách sử dụng các mặt nạ không nhãn được tạo ra từ các mô hình nền tảng như SAM hoặc DINO.[29] Bằng cách sử dụng thuật toán phân cụm trực tuyến và các tên lớp có thể học được, PixelCLIP cải thiện đáng kể khả năng khu trú của CLIP mà không cần giám sát ngữ nghĩa ở mức pixel.[29]

Trong lĩnh vực viễn thám, SegEarth-OV đã giới thiệu khung OVSS không cần huấn luyện cho hình ảnh vệ tinh. Do hình ảnh viễn thám rất nhạy cảm với các đặc trưng độ phân giải thấp, SegEarth-OV sử dụng một bộ upsampler "SimFeatUp" để khôi phục thông tin không gian bị mất trong các đặc trưng sâu của CLIP, giúp cải thiện độ chính xác phân đoạn cho các cấu trúc nhỏ như tòa nhà và đường sá lên lần lượt 8.2% và 4.0% so với các phương pháp SOTA trước đó.[30]

Vai trò của Mô hình Khuếch tán (Diffusion Models)

Mô hình khuếch tán, vốn nổi tiếng trong lĩnh vực tạo ảnh, đang bắt đầu được ứng dụng vào phân đoạn ngữ nghĩa.[32] Quá trình khuếch tán ngược có thể được coi là một quá trình tinh chỉnh hình ảnh, trong đó mô hình học cách khôi phục cấu trúc từ nhiễu.

Các nghiên cứu mới nhất như VidSeg sử dụng các đặc trưng từ mô hình khuếch tán video để thực hiện phân đoạn ngữ nghĩa video mà không cần huấn luyện lại.[35] Bằng cách xây dựng một mô hình ngữ cảnh cảnh quay dựa trên các đặc trưng khuếch tán, VidSeg có thể tạo ra các bản đồ phân đoạn thô nhất quán về mặt thời gian, sau đó được tinh chỉnh để đạt được độ phân giải

cao.[35] Điều này cho thấy tiềm năng to lớn của việc khai thác tri thức ngữ nghĩa ẩn chứa trong các mô hình tạo sinh quy mô lớn cho các nhiệm vụ phân tích thị giác.

Phân đoạn Ngữ nghĩa trong các Lĩnh vực Chuyên biệt

Độ chính xác và khả năng tổng quát hóa của phân đoạn ngữ nghĩa có ý nghĩa sống còn trong nhiều ngành công nghiệp đặc thù, nơi mỗi pixel đều mang thông tin quan trọng.

Y tế và Phân tích Hình ảnh Lâm sàng

Trong y học, phân đoạn ngữ nghĩa hỗ trợ chẩn đoán chính xác bằng cách xác định ranh giới các cơ quan và tổn thương. Tuy nhiên, hình ảnh y tế thường có độ tương phản thấp và ranh giới mờ, gây khó khăn cho các mô hình thông thường.[2]

Mặc dù U-Net vẫn là lựa chọn phổ biến cho các tập dữ liệu nhỏ nhờ cấu trúc encoder-decoder đối xứng và các kết nối tắt (skip connections), xu hướng hiện nay đang chuyển dịch sang các mô hình tổng quát dựa trên nền tảng.[38] Medical SAM3 và CRISP-SAM2 là các nỗ lực thích ứng SAM cho dữ liệu 3D y khoa, sử dụng các gợi ý văn bản để hướng dẫn mô hình nhận diện các cơ quan cụ thể.[27] Một thách thức lớn được xác định là sự suy giảm hiệu suất của các mô hình nền tảng trên các phương thức chẩn đoán hình ảnh như CT và Siêu âm so với MRI do độ tương phản kém.[16] Các kỹ thuật như học cộng tác đa góc nhìn (multi-view collaborative learning) đang được phát triển để hợp nhất thông tin từ các mặt cắt axial, sagittal và coronal nhằm tăng cường chất lượng nhãn giả (pseudo-labels) trong học bán giám sát.[41]

Xe tự lái và Hiểu bối cảnh Đô thị

Đối với xe tự lái, phân đoạn ngữ nghĩa là thành phần cốt lõi của hệ thống nhận thức. Các bộ dữ liệu như Cityscapes và nuScenes cung cấp môi trường thử nghiệm khắc nghiệt với hàng chục lớp đối tượng phức tạp.[4]

Sự dịch chuyển từ phân đoạn 2D sang lưới chiếm chỗ (occupancy grids) 3D là một xu hướng đáng chú ý. UniOcc (2025) kết hợp nhận thức chiếm chỗ và dự báo trong một khung duy nhất, giúp xe hiểu không chỉ không gian hiện tại mà cả hướng di chuyển của các đối tượng xung quanh.[42] Ngoài ra, việc xử lý các điều kiện thời tiết khắc nghiệt (như mưa lớn, ánh sáng chói) thông qua các tập dữ liệu như Adver-City là cực kỳ quan trọng để đảm bảo tính an toàn của hệ thống tự lái trong điều kiện thực tế.[42] Các mô hình như SSP (Semantic Similarity Propagation) đề xuất việc truyền dẫn dự đoán qua các khung hình video bằng cách đăng ký toàn cục (global registration) để bù đắp cho chuyển động của camera, đạt được sự nhất quán tạm thời cao cho các phương tiện bay không người lái (UAV).[20]

Viễn thám và Giám sát Trái đất

Hình ảnh viễn thám đòi hỏi khả năng xử lý các biến đổi quy mô lớn và các đặc trưng phổ phức tạp.[31] Các mô hình SOTA hiện nay thường kết hợp phân đoạn ngữ nghĩa với ước tính độ cao để

tạo ra sự hiểu biết cảnh quan 3D.[43] Việc tích hợp dữ liệu đa phương thức (như kết hợp ảnh quang học Sentinel-2 với ảnh radar Sentinel-1) trong các thách thức như ISASeg 2025 cho phép tạo ra các bản đồ lớp phủ mặt đất siêu phân giải mà không cần dữ liệu độ phân giải cực cao đắt đỏ.[45]

Các Chỉ số và Bảng xếp hạng SOTA (2025-2026)

Hiệu suất của các mô hình phân đoạn ngữ nghĩa thường được đánh giá qua chỉ số $mIoU$ (Mean Intersection over Union), đo lường mức độ chồng lấp giữa vùng dự đoán và vùng thực tế.

$$\text{IoU} = \frac{\text{Diện tích vùng giao}}{\text{Diện tích vùng hợp}} = \frac{TP}{TP + FP + FN}$$

Trong đó TP là True Positive, FP là False Positive và FN là False Negative. Chỉ số $mIoU$ là trung bình cộng IoU của tất cả các lớp.[4]

Bảng xếp hạng trên ADE20K (Scene Parsing)

ADE20K là một trong những bộ dữ liệu khó nhất với 150 danh mục đối tượng trong các bối cảnh sinh hoạt hàng ngày.[4]

Xếp hạng	Tên Mô hình	Kiến trúc Backbone	mIoU	Trạng thái
1	InternImage-H	DCNv3 (3B params)	62.9	Open-source SOTA [13]
2	BEiT-3	ViT-G	62.8	Foundation Model [24]
3	ViT-CoMer	ViT-L with Conv interaction	62.1	Dense Prediction SOTA [24]
4	EVA	ViT-G	61.5	Large-scale Pretraining [24]
5	FD-SwinV2-G	Swin-G	61.4	Distillation-based [24]

Bảng xếp hạng trên Cityscapes (Urban Segmentation)

Cityscapes tập trung vào các cảnh quay đường phố đô thị với yêu cầu độ chính xác biên rất cao.[4]

Mô hình	Loại Phân đoạn	Điểm số (mIoU/PQ)	Đặc điểm Kỹ thuật
DeepLabV3+	Semantic	89.3	ASPP + Decoder refinement [6]
VLTSeg	Semantic	86.4	Transformer-based [4]
InternImage-H	Semantic	86.1	Deformable Convolutions [4]
Panoptic-DeepLab	Panoptic	68.5 (PQ)	SWideRNet backbone [47]
SegFormer-B5	Semantic	84.0	Lightweight Transformer [9]

Kỹ thuật Dữ liệu và Các Thách thức trong Tương lai

Khi các mô hình trở nên lớn hơn, gánh nặng về dữ liệu dán nhãn trở thành nút thắt cổ chai chính. Việc dán nhãn một hình ảnh phân đoạn ngữ nghĩa có thể mất từ vài giờ đến hàng chục giờ tùy độ phức tạp.[2]

Chiến lược Dữ liệu Hiệu quả

Để giải quyết vấn đề này, các đội ngũ chuyên nghiệp đang áp dụng quy trình AI-assisted labeling (Dán nhãn hỗ trợ bởi AI). Thay vì vẽ thủ công từng pixel, các công cụ như Encord tận dụng SAM hoặc YOLOv8-seg để tạo ra các mặt nạ khởi đầu, sau đó con người chỉ đóng vai trò biên tập viên.[4] Việc sử dụng "Honeypots" (các hình ảnh tiêu chuẩn vàng được chèn bí mật) giúp kiểm soát chất lượng của các nhãn do con người tạo ra.[4]

Học liên tục (Continual Learning) cũng là một hướng đi quan trọng để đối phó với sự dịch chuyển miền (domain shift). Các phương pháp như CUE (Continual Universal Segmentation) đề xuất tách biệt kiến trúc thành phần hiểu ngữ nghĩa mức cao và phần tinh chỉnh ranh giới mức thấp, giúp mô hình học các lớp mới mà không quên các lớp cũ (catastrophic forgetting).[48]

Độ tin cậy và Ước tính Độ bất định

Trong các ứng dụng an toàn tính mạng, mô hình không chỉ cần dự đoán đúng mà còn phải biết khi nào nó "không chắc chắn". Các phương pháp ước tính độ bất định (Uncertainty Estimation) thông qua ngưỡng tin cậy (confidence thresholding) hoặc mạng Dirichlet Prior giúp hệ thống nhận diện các đối tượng lạ (OOD) và đưa ra cảnh báo kịp thời.[2] Điều này đặc biệt quan trọng trong xe tự lái khi gặp các vật thể hiếm gặp như hàng hóa rơi vãi hoặc biển báo bị che khuất.[42]

Tương lai: Hiểu biết Thế giới và Đa phương thức

Tương lai của phân đoạn ngữ nghĩa không còn dừng lại ở việc gán nhãn pixel tĩnh. Các mô hình thế giới (World Models) đang được phát triển để đánh giá khả năng tuân thủ các quy luật vật lý của video sinh ra bởi AI.[49] Các mô hình như SAM 3D hướng tới việc khôi phục cấu trúc 3D của vật thể và con người từ một hình ảnh duy nhất, mở ra kỷ nguyên mới cho AR/VR và robot học.[22]

Việc kết hợp đa phương thức (hình ảnh, LiDAR, radar, văn bản và âm thanh) sẽ giúp các hệ thống AI có cái nhìn toàn diện và đáng tin cậy hơn về thế giới thực.[37] Đồng thời, nỗ lực làm cho các mô hình này nhẹ hơn thông qua nén mạng (pruning), lượng tử hóa (quantization) và chưng cất tri thức (knowledge distillation) sẽ cho phép triển khai các khả năng SOTA này trên các thiết bị di động và robot biên trong thời gian thực.[32]

Tóm lại, phân đoạn ngữ nghĩa giai đoạn 2024-2026 đang chứng kiến sự hội tụ giữa các kiến trúc chuyên biệt độ chính xác cao và các mô hình nền tảng đa năng. Sự chuyển dịch sang từ vựng mở và khả năng học không cần huấn luyện đang hứa hẹn phá vỡ rào cản về chi phí dữ liệu, đưa trí tuệ nhân tạo thị giác đến gần hơn với khả năng nhận thức linh hoạt như con người.

Nguồn trích dẫn

1. A Survey on Training-free Open-Vocabulary Semantic Segmentation - arXiv, truy cập vào tháng 2 15, 2026, https://arxiv.org/html/2505.22209v1
2. Understanding Semantic Segmentation in 2025: Key Challenges, Techniques, and Real-World | Umang Dayal | Medium, truy cập vào tháng 2 15, 2026, https://medium.com/@umangdayal2023/understanding-semantic-segmentation-in-2025-key-challenges-techniques-and-real-world-50d07959fe63
3. (PDF) A Survey on Image Semantic Segmentation Using Deep ..., truy cập vào tháng 2 15, 2026, https://www.researchgate.net/publication/366762587_A_Survey_on_Image_Semantic_Segmentation_Using_Deep_Learning_Techniques
4. The 4 Top Datasets for Semantic Segmentation - CVAT, truy cập vào tháng 2 15, 2026, https://www.cvat.ai/resources/blog/top-datasets-semantic-segmentation
5. Semantic Segmentation On Coco Stuff Test | SOTA | HyperAI, truy cập vào tháng 2 15, 2026, https://hyper.ai/en/sota/tasks/semantic-segmentation/benchmark/semantic-segmentation-on-coco-stuff-test
6. 7 Best Semantic Segmentation Models (2026) - Averroes AI, truy cập vào tháng 2

15, 2026, https://averroes.ai/blog/best-semantic-segmentation-models
7. [PDF] InternImage: Exploring Large-Scale Vision Foundation Models with Deformable Convolutions | Semantic Scholar, truy cập vào tháng 2 15, 2026, https://www.semanticscholar.org/paper/InternImage%3A-Exploring-Large-Scale-Vision-Models-Wang-Dai/26c80bd65baa90f5b18157de4951f4eb0b62ab69
8. InternImage: Large-Scale Vision Model with Deformable Convolutions | PDF - Scribd, truy cập vào tháng 2 15, 2026, https://www.scribd.com/document/722939894/InternImage-Exploring-Large-Scale-Vision-Foundation-Models-with-Deformable-Convolutions
9. Best Image Segmentation Models for ML Engineers - Data Annotation Company, truy cập vào tháng 2 15, 2026, https://labelyourdata.com/articles/best-image-segmentation-models
10. Cityscapes Semantic Segmentation DeepLabV3 and SegFormer | by Fadhil Elrizanda, truy cập vào tháng 2 15, 2026, https://medium.com/@fadhilelrizanda/cityscapes-semantic-segmentation-deeplabv3-and-segformer-3064dd2f7a22
11. Inference results of Mask2Former, U-Net, and DeepLabV3+ tested on PV01,... | Download Scientific Diagram - ResearchGate, truy cập vào tháng 2 15, 2026, https://www.researchgate.net/figure/nference-results-of-Mask2Former-U-Net-and-DeepLabV3-tested-on-PV01-PV03-PV08_fig2_380300222
12. Evidential Modeling of Mask Transformers for Assumption-Free Open-World Panoptic Segmentation - arXiv, truy cập vào tháng 2 15, 2026, https://arxiv.org/html/2504.04841v2
13. nischalj10/InternImage - GitHub, truy cập vào tháng 2 15, 2026, https://github.com/nischalj10/InternImage
14. Improvement of SAM2 Algorithm Based on Kalman Filtering for Long-Term Video Object Segmentation - PMC, truy cập vào tháng 2 15, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC12252479/
15. Awesome SAM2 (Segment Anything in Images and Videos) - GitHub, truy cập vào tháng 2 15, 2026, https://github.com/GuoleiSun/Awesome-SAM2
16. Is SAM 2 better than SAM in medical image segmentation? - SPIE Digital Library, truy cập vào tháng 2 15, 2026, https://www.spiedigitallibrary.org/conference-proceedings-of-spie/13406/134062N/Is-SAM-2-better-than-SAM-in-medical-image-segmentation/10.1117/12.3047370.full
17. Introduction to Semantic Segmentation - Encord, truy cập vào tháng 2 15, 2026, https://encord.com/blog/guide-to-semantic-segmentation/
18. SOTA AI Models: Benchmarks, Metrics & Deployment Guide - Hugging Face, truy cập vào tháng 2 15, 2026, https://huggingface.co/blog/daya-shankar/sota-ai-models
19. SAM 3: Segment Anything with Concepts - Ultralytics YOLO Docs, truy cập vào tháng 2 15, 2026, https://docs.ultralytics.com/models/sam-3/
20. CVPR Poster High Temporal Consistency through Semantic Similarity Propagation in Semi-Supervised Video Semantic Segmentation for Autonomous Flight - CVPR 2026, truy cập vào tháng 2 15, 2026,

https://cvpr.thecvf.com/virtual/2025/poster/35092
21. SAM 3: SEGMENT ANYTHING WITH CONCEPTS - OpenReview, truy cập vào tháng 2 15, 2026, https://openreview.net/pdf/9cb68221311aa4d88167b66c0c84ef569e37122f.pdf?ref=blog.roboflow.com
22. New Segment Anything Models Make it Easier to Detect Objects and Create 3D Reconstructions - Meta, truy cập vào tháng 2 15, 2026, https://about.fb.com/news/2025/11/new-sam-models-detect-objects-create-3d-reconstructions/
23. OpenGVLab/internimage_t_1k_224 - Hugging Face, truy cập vào tháng 2 15, 2026, https://huggingface.co/OpenGVLab/internimage_t_1k_224
24. Semantic Segmentation On Ade20k Val | SOTA - HyperAI, truy cập vào tháng 2 15, 2026, https://hyper.ai/en/sota/tasks/semantic-segmentation/benchmark/semantic-segmentation-on-ade20k-val
25. (TPAMI 2024) A Survey on Open Vocabulary Learning - GitHub, truy cập vào tháng 2 15, 2026, https://github.com/jianzongwu/Awesome-Open-Vocabulary
26. A Survey on Training-free Open-Vocabulary Semantic Segmentation - ResearchGate, truy cập vào tháng 2 15, 2026, https://www.researchgate.net/publication/392167587_A_Survey_on_Training-free_Open-Vocabulary_Semantic_Segmentation
27. SAM2 with Cross-Modal Interaction and Semantic Prompting for Multi-Organ Segmentation - arXiv, truy cập vào tháng 2 15, 2026, https://arxiv.org/html/2506.23121v2
28. [2505.22209] A Survey on Training-free Open-Vocabulary Semantic Segmentation - arXiv, truy cập vào tháng 2 15, 2026, https://arxiv.org/abs/2505.22209
29. Towards Open-Vocabulary Semantic Segmentation Without Semantic Labels - NeurIPS, truy cập vào tháng 2 15, 2026, https://neurips.cc/virtual/2024/poster/94555
30. SegEarth-OV: Towards Training-Free Open-Vocabulary Segmentation for Remote Sensing Images, truy cập vào tháng 2 15, 2026, https://openaccess.thecvf.com/content/CVPR2025/papers/Li_SegEarth-OV_Towards_Training-Free_Open-Vocabulary_Segmentation_for_Remote_Sensing_Images_CVPR_2025_paper.pdf
31. SegEarth-OV: Towards Training-Free Open-Vocabulary ..., truy cập vào tháng 2 15, 2026, https://likyoo.github.io/SegEarth-OV
32. [TMLR 2025] Efficient Diffusion Models: A Survey - GitHub, truy cập vào tháng 2 15, 2026, https://github.com/AIoT-MLSys-Lab/Efficient-Diffusion-Model-Survey
33. Diffusion Models in Low-Level Vision: A Survey - IEEE Computer Society, truy cập vào tháng 2 15, 2026, https://www.computer.org/csdl/journal/tp/2025/06/10902142/24AYEq6vO0g
34. Diffusion Models in Vision: A Survey - arXiv, truy cập vào tháng 2 15, 2026, https://arxiv.org/html/2209.04747v6
35. VidSeg: Training-free Video Semantic Segmentation based on Diffusion Models -

CVPR 2025 Open Access Repository, truy cập vào tháng 2 15, 2026, https://openaccess.thecvf.com/content/CVPR2025/html/Wang_VidSeg_Training-free_Video_Semantic_Segmentation_based_on_Diffusion_Models_CVPR_2025_paper.html
36. Recent Advances in Medical Imaging Segmentation: A Survey - arXiv.org, truy cập vào tháng 2 15, 2026, https://arxiv.org/html/2505.09274v1
37. Advances in Deep Learning for Semantic Segmentation of Low-Contrast Images: A Systematic Review of Methods, Challenges, and Future Directions - MDPI, truy cập vào tháng 2 15, 2026, https://www.mdpi.com/1424-8220/25/7/2043
38. Medical SAM3: A Foundation Model for Universal Prompt-Driven Medical Image Segmentation - arXiv, truy cập vào tháng 2 15, 2026, https://arxiv.org/html/2601.10880v1
39. [2506.10825] Generalist Models in Medical Image Segmentation: A Survey and Performance Comparison with Task-Specific Approaches - arXiv, truy cập vào tháng 2 15, 2026, https://arxiv.org/abs/2506.10825
40. Is the medical image segmentation problem solved? A survey ... - arXiv, truy cập vào tháng 2 15, 2026, https://arxiv.org/abs/2508.20139
41. A foundation model-driven multi-view collaborative framework for semi-supervised 3D medical image segmentation - Frontiers, truy cập vào tháng 2 15, 2026, https://www.frontiersin.org/journals/medicine/articles/10.3389/fmed.2025.1744097/full
42. 15 Notable AI Datasets for Autonomous Driving in 2024-2025 | BasicAI's Blog, truy cập vào tháng 2 15, 2026, https://www.basic.ai/blog-post/15-new-autonomous-driving-datasets-in-2024-2025
43. Synergistic Semantic Segmentation and Height Estimation for Monocular Remote Sensing Images via Cross-Task Interaction - MDPI, truy cập vào tháng 2 15, 2026, https://www.mdpi.com/2072-4292/17/9/1637
44. A Survey of Remote Sensing Image Segmentation Based on Deep Learning, truy cập vào tháng 2 15, 2026, https://www.researchgate.net/publication/399977955_A_Survey_of_Remote_Sensing_Image_Segmentation_Based_on_Deep_Learning
45. ISASeg: 2025 Multimodal Semantic Segmentation Challenge – Workshop on Hyperspectral Images and Signal Processing : an Evolution in Remote Sensing - IEEE Whispers, truy cập vào tháng 2 15, 2026, https://www.ieee-whispers.com/multimodal-semantic-segmentation-challenge/
46. ADE20K - Dataset Ninja, truy cập vào tháng 2 15, 2026, https://datasetninja.com/ade20k
47. Benchmark Suite - Cityscapes Dataset, truy cập vào tháng 2 15, 2026, https://www.cityscapes-dataset.com/benchmarks/
48. CVPR Poster Towards Continual Universal Segmentation, truy cập vào tháng 2 15, 2026, https://cvpr.thecvf.com/virtual/2025/poster/34753
49. NeurIPS 2025 San Diego Datasets & Benchmarks, truy cập vào tháng 2 15, 2026, https://neurips.cc/virtual/2025/loc/san-diego/events/datasets-benchmarks-2025