Texture-Aware Lightweight Semantic Segmentation for Fine-Grained Food Images

Nguyễn Anh Thư, Nguyễn Thiên Nhã Trân
Khoa Công nghệ Thông tin
Đại học Quốc gia Thành phố Hồ Chí Minh — Trường Đại học Khoa học Tự nhiên
Thành phố Hồ Chí Minh, Việt Nam
23127266@student.hcmus.edu.vn, 23127272@student.hcmus.edu.vn

Abstract—Xuất phát từ yêu cầu cân bằng giữa chất lượng phân đoạn và hiệu quả suy luận trong các kịch bản triển khai có tài nguyên tính toán hạn chế, báo cáo này khảo sát bài toán phân đoạn nguyên liệu thực phẩm fine-grained trên FoodSeg103 dưới góc nhìn lightweight segmentation. Phân tích dữ liệu cho thấy FoodSeg103 có phân bố long-tail mạnh, ranh giới mờ, chồng lấp cao và chênh lệch độ phân giải giữa các split, khiến việc huấn luyện mô hình nhẹ dễ thiên lệch và suy giảm chi tiết cục bộ. Trên cơ sở đó, nghiên cứu xây dựng quy trình làm sạch và tái cấu trúc không gian nhãn bằng gộp lớp theo ngữ nghĩa và tương đồng texture, qua đó giảm số lớp mục tiêu từ 103 xuống 75 trong khi vẫn giữ gần như toàn bộ mẫu hợp lệ. Từ bộ dữ liệu sau xử lý, một baseline BiSeNet được chuẩn hóa với pipeline huấn luyện, augmentation và đánh giá nhất quán theo mIoU, mAcc và pixel accuracy nhằm làm rõ mức độ phù hợp của kiến trúc lightweight đối với bài toán này. Kết quả của bước nghiên cứu nền tảng này cung cấp một mốc tham chiếu rõ ràng cho các cải tiến texture-aware trong giai đoạn tiếp theo và hỗ trợ xác định cấu hình khả thi hơn cho triển khai thực tế.

Index Terms—FoodSeg103, semantic segmentation, long-tail imbalance, data rebalancing, BiSeNet baseline

I. Giới thiệu

Phân đoạn ngữ nghĩa là bài toán gán nhãn cho từng pixel trong ảnh đầu vào, trong đó mô hình phải đồng thời nắm bắt ngữ cảnh toàn cục và bảo toàn các tín hiệu cục bộ. Về mặt hình thức, với ảnh đầu vào

$$\mathbf{X} \in \mathbb{R}^{H \times W \times 3},$$

mục tiêu là dự đoán bản đồ nhãn

$$\mathbf{Y} \in \{1, 2, \ldots, K\}^{H \times W},$$

trong đó H, W là kích thước ảnh và K là số lớp cần phân đoạn. Thiết lập này đặc biệt quan trọng trong các hệ thống theo dõi dinh dưỡng, bếp thông minh, robot chế biến và kiểm soát chất lượng thực phẩm, nơi yêu cầu về độ chính xác phải đi kèm với khả năng suy luận hiệu quả trong thực tế [21]–[24].

Trong miền ảnh thực phẩm, bài toán trở nên khó hơn đáng kể vì mỗi pixel không chỉ cần được gán đúng nhãn ngữ nghĩa, mà còn phải được tách khỏi các thành phần nguyên liệu lân cận có hình thái và màu sắc gần nhau. Các thành phần này thường chồng lấp, có ranh giới mờ, biến đổi mạnh theo cách chế biến và mang tính fine-grained rõ rệt. Do đó, chất lượng phân đoạn không chỉ phụ thuộc vào khả năng mô hình hóa ngữ cảnh, mà còn phụ thuộc mạnh vào việc giữ được biên, texture và cấu trúc bề mặt như những tín hiệu phân biệt cục bộ then chốt.

FoodSeg103 là benchmark tiêu biểu cho thiết lập ingredient-level này [6]. Tuy nhiên, đây cũng là một benchmark khó: số lớp lớn, biến thiên nội lớp cao, tương đồng liên lớp mạnh, phân bố đuôi dài nghiêm trọng và mỗi ảnh thường chứa nhiều nguyên liệu cùng lúc. Những đặc tính đó khiến mô hình dễ thiên lệch về lớp phổ biến, làm mịn ranh giới và bỏ sót các lớp hiếm, đặc biệt khi kiến trúc không đủ nhạy với local detail.

Vấn đề nghiên cứu vì thế nằm ở sự đánh đổi giữa độ chính xác và hiệu quả suy luận. Các mô hình segmentation mạnh giàu ngữ cảnh có thể cho kết quả tốt hơn nhưng thường đòi hỏi chi phí tính toán cao, khó triển khai trên thiết bị tài nguyên hạn chế. Ngược lại, các kiến trúc lightweight đạt tốc độ cao nhờ downsample sớm và nén biểu diễn, nhưng chính chiến lược đó có thể làm suy giảm các đặc trưng cục bộ quan trọng đối với ảnh thực phẩm fine-grained. Trong bối cảnh đó, nghiên cứu hiện tại được định vị như một baseline study: thay vì tuyên bố đã giải quyết hoàn chỉnh bài toán texture-aware lightweight segmentation, báo cáo tập trung xây dựng một nền tảng thực nghiệm nhất quán thông qua tái cấu trúc dữ liệu để giảm tác động của long-tail imbalance và chuẩn hóa baseline BiSeNet làm mốc tham chiếu cho các cải tiến texture/local-detail-aware ở giai đoạn tiếp theo.

Từ định vị đó, báo cáo tập trung vào ba đóng góp chính:

- Phân tích định lượng bộ dữ liệu FoodSeg103 để chỉ ra các khó khăn cốt lõi của bài toán, bao gồm long-tail imbalance, chồng lấp thành phần, ranh giới yếu và chênh lệch độ phân giải giữa các split.
- Xây dựng quy trình làm sạch và tái cấu trúc không gian nhãn dựa trên ngữ nghĩa và tương đồng texture, qua đó giảm số lớp mục tiêu từ 103 xuống 75 trong khi vẫn giữ gần như toàn bộ dữ liệu hợp lệ.
- Thiết lập và chuẩn hóa baseline BiSeNet trên bộ dữ liệu đã xử lý để tạo mốc tham chiếu công bằng cho các nghiên cứu texture-aware lightweight segmentation tiếp theo.

A. Phát biểu bài toán

Bài toán phân đoạn ngữ nghĩa (semantic segmentation) là bài toán gán nhãn ngữ nghĩa cho từng điểm ảnh trong ảnh đầu vào. Với một ảnh đầu vào

$$\mathbf{X} \in \mathbb{R}^{H \times W \times 3},$$

mục tiêu là dự đoán một bản đồ nhãn

$$\mathbf{Y} \in \{1, 2, \ldots, K\}^{H \times W},$$

trong đó H, W lần lượt là chiều cao và chiều rộng của ảnh, còn K là số lớp cần phân đoạn.

Trong bài toán phân đoạn ảnh thực phẩm ở mức nguyên liệu, mỗi pixel cần được gán vào một lớp nguyên liệu tương ứng, ví dụ như rice, beef, lettuce, tomato, ...Với mô hình học sâu, mạng nhận ảnh đầu vào $\mathbf{X}$ và sinh ra tensor logit

$$\mathbf{Z} \in \mathbb{R}^{H \times W \times K},$$

trong đó $\mathbf{Z}_{i,j,c}$ biểu diễn điểm số chưa chuẩn hóa của lớp c tại pixel (i, j). Xác suất dự đoán cho lớp c tại pixel (i, j) được tính bằng hàm softmax:

$$p_{i,j,c} = \frac{\exp(\mathbf{Z}_{i,j,c})}{\sum_{k=1}^{K} \exp(\mathbf{Z}_{i,j,k})}.$$

Nhãn dự đoán cuối cùng tại pixel (i, j) được xác định bởi:

$$\hat{y}_{i,j} = \arg \max_{c \in \{1,\ldots,K\}} p_{i,j,c}.$$

Như vậy, bài toán phân đoạn ngữ nghĩa có thể xem là bài toán phân lớp đa lớp ở mức pixel, trong đó mô hình phải đồng thời học được ngữ cảnh toàn cục và bảo toàn các chi tiết cục bộ như biên, texture và cấu trúc bề mặt để phân biệt các lớp có mức độ tương đồng thị giác cao.

B. Hàm mất mát

Trong nghiên cứu này, mô hình được huấn luyện bằng hàm mất mát pixel-wise cross-entropy. Gọi $y_{i,j}$ là nhãn thật tại pixel (i, j), khi đó hàm mất mát trên toàn ảnh được viết là:

$$\mathcal{L}_{\text{CE}} = -\frac{1}{|\Omega|} \sum_{(i,j) \in \Omega} \log p_{i,j,y_{i,j}},$$

trong đó Ω là tập các pixel hợp lệ được dùng để huấn luyện, và $|\Omega|$ là số lượng pixel trong tập này.

Viết tường minh theo đầu ra softmax, ta có:

$$\mathcal{L}_{\text{CE}} = -\frac{1}{|\Omega|} \sum_{(i,j) \in \Omega} \log \left(\frac{\exp(\mathbf{Z}_{i,j,y_{i,j}})}{\sum_{c=1}^{K} \exp(\mathbf{Z}_{i,j,c})} \right).$$

Hàm mất mát này buộc mô hình tăng xác suất cho lớp đúng tại từng pixel. Trong thực tế, nếu dữ liệu có mất cân bằng lớp mạnh, có thể mở rộng sang weighted cross-entropy; tuy nhiên, dạng cơ sở được sử dụng trong báo cáo này là cross-entropy chuẩn ở mức pixel.

C. Các chỉ số đánh giá

Để đánh giá chất lượng phân đoạn, ta xét theo từng lớp c. Gọi:

- TP_c là số pixel thuộc lớp c và được dự đoán đúng là lớp c;
- FP_c là số pixel không thuộc lớp c nhưng bị dự đoán nhầm thành lớp c;
- FN_c là số pixel thuộc lớp c nhưng bị dự đoán nhầm sang lớp khác.

Khi đó, Intersection over Union của lớp c được định nghĩa là:

$$\text{IoU}_c = \frac{TP_c}{TP_c + FP_c + FN_c}.$$

D. Mean IoU trên các lớp xuất hiện

Chỉ số đánh giá chính trong nghiên cứu này là mean Intersection over Union (mIoU). Tuy nhiên, thay vì lấy trung bình trên toàn bộ K lớp cố định, mIoU được tính trên các lớp thực sự xuất hiện trong tập đánh giá. Đây là điểm cần nhấn mạnh để tránh làm sai lệch kết quả trong bối cảnh dữ liệu có phân bố lớp thưa và không phải lớp nào cũng xuất hiện trong mỗi pha đánh giá.

Gọi tập các lớp xuất hiện là:

$$\mathcal{C}_{\text{present}} = \{c \in \{1, \ldots, K\} \mid TP_c + FN_c > 0\}.$$

Tức là một lớp được xem là xuất hiện nếu nó có ít nhất một pixel ground-truth trong tập đánh giá.

Khi đó, mIoU được tính như sau:

$$\text{mIoU} = \frac{1}{|\mathcal{C}_{\text{present}}|} \sum_{c \in \mathcal{C}_{\text{present}}} \text{IoU}_c.$$

Cách tính này phản ánh đúng hơn chất lượng phân đoạn trên các lớp thực sự có mặt, thay vì đưa cả những lớp không xuất hiện vào mẫu số trung bình. Do đó, đây là chỉ số phù hợp hơn cho các bài toán phân đoạn thực phẩm fine-grained, nơi phân bố lớp thường mất cân bằng và không đồng đều giữa các mẫu.

E. Chỉ số bổ sung

Ngoài mIoU, có thể báo cáo thêm một số chỉ số bổ sung để hỗ trợ phân tích:

a) Mean Accuracy (mAcc).: Độ chính xác theo từng lớp được định nghĩa là:

$$\text{Acc}_c = \frac{TP_c}{TP_c + FN_c}.$$

Tương tự, trung bình trên các lớp xuất hiện là:

$$\text{mAcc} = \frac{1}{|\mathcal{C}_{\text{present}}|} \sum_{c \in \mathcal{C}_{\text{present}}} \text{Acc}_c.$$

b) Overall Accuracy (aAcc).: Độ chính xác toàn cục trên tất cả pixel:

$$\text{aAcc} = \frac{\sum_c TP_c}{\sum_c (TP_c + FN_c)}.$$

Tuy nhiên, trong báo cáo này, mIoU được sử dụng làm chỉ số chính vì đây là thước đo phù hợp hơn cho bài toán phân đoạn ngữ nghĩa nhiều lớp, đặc biệt trong trường hợp dữ liệu mất cân bằng giữa các lớp.

II. Các nghiên cứu liên quan

Phần này chỉ tập trung vào ba câu hỏi trực tiếp dẫn đến đề tài: FoodSeg103 khó ở đâu, các mô hình segmentation nhẹ đang đánh đổi điều gì, và các cơ chế tăng cường chi tiết cục bộ có thật sự gợi mở một hướng phù hợp cho dữ liệu thực phẩm hay không.

A. Fine-grained food segmentation và benchmark FoodSeg103

Phân đoạn ảnh thực phẩm ở mức nguyên liệu khó hơn rõ rệt so với semantic segmentation tổng quát vì nhiều lớp có hình dạng tổng thể gần nhau nhưng khác nhau ở texture, trạng thái bề mặt và chất lượng biên [6]. Trong cùng một ảnh, các nguyên liệu thường chồng lấp, bị che khuất một phần và có ranh giới yếu sau chế biến. Vì vậy, local detail đóng vai trò trực tiếp trong việc phân biệt lớp, thay vì chỉ là tín hiệu bổ trợ.

Fig. 1: Mẫu ảnh đại diện của FoodSeg103, cho thấy độ đa dạng cao về texture, màu sắc và trạng thái bề mặt giữa các nguyên liệu.

FoodSeg103 là benchmark ingredient-level tiêu biểu cho bài toán này [6]. Bộ dữ liệu gồm 7,118 ảnh, 103 lớp nguyên liệu và 42,097 mask; trong đó tập huấn luyện có 4,983 ảnh và tập đánh giá có 2,135 ảnh. Kết quả benchmark ban đầu cho thấy DeepLabv3+ chỉ đạt 34.2 mIoU trên FoodSeg103, thấp hơn đáng kể so với khi đánh giá trên các bộ dữ liệu food segmentation đơn giản hơn [6]. Điều đó cho thấy khó khăn chính không nằm ở việc nhận diện món ăn nói chung, mà ở khả năng tách chính xác từng nguyên liệu có tín hiệu phân biệt rất mịn.

Nhóm công trình này làm tốt ở chỗ xác lập một benchmark thực sự khó và chỉ ra vai trò của semantic prior, ví dụ ReLeM giúp SeTR tăng từ 41.3 lên 43.9 mIoU [6]. Tuy nhiên, các hướng mạnh về biểu diễn hoặc tri thức đa phương thức vẫn chưa giải quyết trực tiếp bài toán triển khai nhẹ. Vì vậy, giá trị lớn nhất của nhánh này đối với đề tài hiện tại là làm rõ rằng FoodSeg103 đòi hỏi mô hình phải nhạy với texture, boundary và class imbalance, chứ không chỉ mạnh về ngữ cảnh toàn cục.

B. Lightweight semantic segmentation cho triển khai hiệu quả

Nhóm công trình thứ hai tập trung vào trade-off giữa độ chính xác và chi phí suy luận. Các mô hình như BiSeNet, Fast-SCNN và PIDNet sử dụng backbone nhẹ, downsampling chiến lược hoặc kiến trúc đa nhánh để giảm tham số, FLOPs và độ trễ [3], [16], [20]. Trên Cityscapes, BiSeNet đạt 68.4% mIoU ở 105 FPS, Fast-SCNN đạt 68.0% mIoU ở 123.5 FPS với 1.11M tham số, còn PIDNet-S đạt 78.6% mIoU ở 93.2 FPS với 7.6M tham số [3], [16], [20].

Điểm mạnh của nhóm này là chứng minh rằng segmentation thời gian thực hoàn toàn khả thi nếu kiến trúc được tổ chức hợp lý. Đặc biệt, BiSeNet đáng chú ý vì tách riêng nhánh giữ chi tiết không gian và nhánh học ngữ cảnh, nên phù hợp để làm baseline khi mục tiêu là phân tích rõ phần nào của kiến trúc còn thiếu cho dữ liệu fine-grained.

Tuy nhiên, điểm yếu của lightweight segmentation cũng khá rõ. Phần lớn lợi ích về tốc độ đến từ việc nén biểu diễn hoặc giảm độ phân giải đặc trưng sớm, trong khi đó lại là thao tác dễ làm mất texture và boundary cues. Trên các benchmark cảnh đường phố, mất mát này đôi khi còn chấp nhận được vì lớp vẫn có cấu trúc hình học lớn và ngữ cảnh mạnh. Trên FoodSeg103 thì ngược lại: mô hình nhẹ có nguy cơ bỏ mất đúng loại tín hiệu mà bài toán cần nhất. Vì vậy, lightweight models là nền tảng tốt cho triển khai, nhưng tự thân chúng chưa đủ cho ingredient-level food segmentation.

C. Các cơ chế tăng cường chi tiết cục bộ và texture-aware

Để bù lại phần thông tin cục bộ bị mất trong các kiến trúc gọn nhẹ, nhiều nghiên cứu đề xuất các cơ chế detail-enhanced hoặc texture-aware. Gated-SCNN học thông tin biên qua một shape stream riêng [17]; PIDNet kết hợp ba nhánh detail, context và boundary để cải thiện mask mà không phình to backbone quá mức [20]; PointRend chỉ tinh chỉnh tại các điểm bất định cao quanh ranh giới [18]; còn Deep-TEN cho thấy texture có thể được biểu diễn như một tín hiệu thống kê có cấu trúc thay vì chỉ là pattern cục bộ rời rạc [19].

Điểm chung của các hướng này là chúng không cố giải quyết vấn đề bằng cách làm mạng lớn hơn, mà tổ chức lại nơi nào cần giữ chi tiết và nơi nào cần refinement. Đây là một lập luận rất phù hợp với ảnh thực phẩm, nơi sai số quan trọng thường tập trung ở vùng giao nhau giữa các nguyên liệu hoặc ở các lớp có bề mặt gần giống nhau.

Dù vậy, bằng chứng thực nghiệm cho các cơ chế này dưới ràng buộc lightweight food segmentation vẫn còn hạn chế. Phần lớn chúng được kiểm chứng trên benchmark tổng

quát hoặc đô thị, nơi biên rõ và cấu trúc hình học ổn định hơn. Vì thế, khoảng trống nghiên cứu không phải là thiếu ý tưởng detail-aware, mà là thiếu một pipeline baseline đủ sạch để kiểm tra có hệ thống xem các ý tưởng đó có thật sự cải thiện trade-off accuracy–efficiency trên FoodSeg103 hay không.

D. Khoảng trống nghiên cứu và vị trí của bài hiện tại

Từ ba nhóm công trình trên có thể rút ra một kết luận chung. Các mô hình mạnh trên FoodSeg103 cho thấy bài toán cần ngữ cảnh và biểu diễn tốt; các mô hình nhẹ cho thấy triển khai hiệu quả là khả thi; còn các hướng detail-aware cho thấy local refinement là một giả thuyết hợp lý để giảm mất mát chi tiết. Nhưng ba hướng này chưa được nối với nhau một cách chặt chẽ trên cùng một thiết lập baseline nhẹ và dữ liệu đã được xử lý ổn định.

Do đó, bài hiện tại không cố tuyên bố một mô-đun texture-aware mới đã vượt trội hơn state of the art. Thay vào đó, nghiên cứu tập trung vào bước nền: phân tích dữ liệu, tái cân bằng không gian nhãn và chuẩn hóa baseline BiSeNet trên FoodSeg103_rebalanced. Đây là điểm tựa cần thiết để các nghiên cứu tiếp theo có thể đánh giá công bằng các cải tiến texture-aware hoặc boundary-aware dưới cùng một điều kiện thực nghiệm.

III. Phương pháp

A. Mục tiêu baseline

Phần baseline được xây dựng nhằm thiết lập một mốc tham chiếu hiệu năng cho bài toán phân vùng đa lớp thực phẩm trên bộ dữ liệu FoodSeg103_rebalanced. BiSeNet (Bilateral Segmentation Network) được chọn vì đây là một kiến trúc lightweight kinh điển có chủ đích tách riêng đường đi của chi tiết không gian và ngữ cảnh ngữ nghĩa, từ đó phù hợp để làm mốc so sánh cho các cải tiến texture-aware trong giai đoạn sau.

Việc thiết lập baseline với BiSeNet tập trung vào ba mục tiêu:

- Thiết lập mốc hiệu năng: tạo một điểm tham chiếu rõ ràng về độ chính xác và chi phí tính toán trên dữ liệu đã được tái cân bằng.
- Kiểm tra giới hạn của mô hình nhẹ: đánh giá xem một kiến trúc thời gian thực như BiSeNet suy giảm ra sao trên bài toán ingredient-level có ranh giới yếu và texture phức tạp.
- Chuẩn hóa pipeline: định nghĩa quy trình huấn luyện và đánh giá đồng nhất để làm cơ sở so sánh công bằng cho các mô-đun texture-aware hoặc boundary-aware ở bước tiếp theo.

B. Kiến trúc chi tiết của BiSeNet baseline

Theo đề xuất của Changqian Yu và cộng sự, BiSeNet được cấu thành từ hai thành phần chính nhằm giải quyết hai yêu cầu mâu thuẫn trong phân vùng ngữ nghĩa: bảo toàn chi tiết không gian và mở rộng trường thụ cảm [3]. Đây cũng chính là lý do mô hình được chọn cho nghiên cứu hiện tại: nó đủ nhẹ để đại diện cho ràng buộc triển khai, nhưng vẫn có sẵn cấu trúc cho phép phân tích phần mất mát local detail.

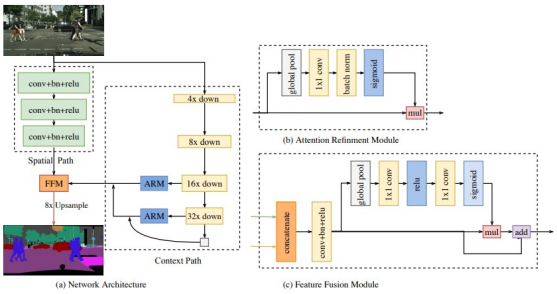

Fig. 2. An overview of the Bilateral Segmentation Network. (a) Network Architecture. The length of block indicates the spatial size, while the thickness represents the number of channels. (b) Components of the Attention Refinement Module (ARM). (c) Components of the Feature Fusion Module (FFM). The read line represents we take this process only when testing.

- Spatial Path (Nhánh không gian): Thay vì sử dụng các phép tích chập giãn (dilated convolution) gây tốn kém tính toán, nhánh này chỉ gồm 3 tầng tích chập với stride = 2. Nhánh này trích xuất đặc trưng có kích thước bằng 1/8 ảnh gốc, giúp bảo toàn các chi tiết cạnh và cấu trúc bề mặt của thực phẩm vốn rất dễ bị mất đi khi downsampling quá sâu.
- Context Path (Nhánh ngữ cảnh): Nhánh này sử dụng một backbone nhẹ (như Xception hoặc ResNet18) kết hợp với Global Average Pooling (GAP) để mở rộng tối đa trường thụ cảm. Điều này giúp mạng hiểu được mối quan hệ giữa các thành phần thực phẩm trong cùng một đĩa ăn (ví dụ: cơm thường đi kèm với thức ăn mặn).
- Attention Refinement Module (ARM): Được tích hợp vào hai giai đoạn cuối của Context Path. ARM sử dụng attention theo kênh (channel-wise attention) để tinh lọc đặc trưng, giúp mạng tập trung vào các vùng ngữ nghĩa quan trọng mà không làm tăng đáng kể chi phí tính toán.
- Feature Fusion Module (FFM): Do đặc trưng từ Spatial Path là mức thấp (low-level) còn Context Path là mức cao (high-level), chúng không thể cộng trực tiếp. FFM thực hiện nối (concatenate) hai luồng đặc trưng, sau đó sử dụng một cấu trúc tương tự SENet để tái trọng số hóa các kênh, đảm bảo sự hòa hợp giữa chi tiết không gian và thông tin ngữ cảnh.

C. Hàm mất mát và Chiến lược huấn luyện

Mô hình được huấn luyện bằng một principal loss tại đầu ra cuối cùng và hai auxiliary loss gắn vào các đầu ra trung gian của Context Path theo cơ chế deep supervision. Do đó, hàm mất mát tổng được viết tường minh như sau:

$$\mathcal{L} = \mathcal{L}_p + \alpha\mathcal{L}_2 + \alpha\mathcal{L}_3,$$

trong đó $\mathcal{L}_p$ là loss tại đầu ra chính sau Feature Fusion Module, còn $\mathcal{L}_2$ và $\mathcal{L}_3$ lần lượt là hai loss phụ tương ứng

với hai đầu ra trung gian được lấy từ Context Path. Trong BiSeNet, hệ số cân bằng được đặt là $\alpha = 1$.

Cả ba thành phần trên đều dùng pixel-wise softmax cross-entropy. Với một đầu ra bất kỳ $o \in \{p, 2, 3\}$, ta có:

$$\mathcal{L}_o = -\frac{1}{|\Omega|} \sum_{(i,j)\in\Omega} \log p^{(o)}_{i,j,y_{i,j}},$$

trong đó $y_{i,j}$ là nhãn thật của pixel (i, j), Ω là tập pixel hợp lệ, còn $p^{(o)}_{i,j,c}$ là xác suất softmax của lớp c tại pixel (i, j) ở đầu ra o, được tính từ logit $z^{(o)}_{i,j,c}$:

$$p^{(o)}_{i,j,c} = \frac{\exp(z^{(o)}_{i,j,c})}{\sum_{k=1}^{C} \exp(z^{(o)}_{i,j,k})}.$$

Viết riêng từng thành phần, ta có:

$$\mathcal{L}_p = -\frac{1}{|\Omega|} \sum_{(i,j)\in\Omega} \log p^{(p)}_{i,j,y_{i,j}}.$$

$$\mathcal{L}_2 = -\frac{1}{|\Omega|} \sum_{(i,j)\in\Omega} \log p^{(2)}_{i,j,y_{i,j}}.$$

$$\mathcal{L}_3 = -\frac{1}{|\Omega|} \sum_{(i,j)\in\Omega} \log p^{(3)}_{i,j,y_{i,j}}.$$

Thiết kế này giúp đầu ra cuối cùng học trực tiếp mục tiêu phân đoạn, trong khi hai nhánh phụ hỗ trợ quá trình lan truyền gradient ở Context Path và làm tối ưu ổn định hơn trong giai đoạn huấn luyện. Các auxiliary loss chỉ được dùng ở pha huấn luyện; khi suy luận, mô hình chỉ sử dụng đầu ra chính.

IV. Thực nghiệm

A. Quy trình cân bằng lại dữ liệu

Trong phân đoạn ảnh thực phẩm, kết cấu bề mặt đặc biệt quan trọng vì thực phẩm dễ biến dạng khi chế biến và thường phụ thuộc nhiều vào màu sắc cùng kết cấu hơn là hình dạng. Việc gộp các lớp tương đồng về kết cấu bề mặt giúp giảm mất cân bằng lớp và tạo điều kiện cho mô hình học đặc trưng thị giác vững chắc.

Vào 2023, Cote và cộng sự đã tiến hành nghiên cứu tầm quan trọng của việc khai thác dữ liệu vân của một tập dữ liệu gạch mosaic đa dạng. Kết quả cho thấy rằng kết cấu bề mặt là đặc trưng then chốt để phân biệt các vùng, đồng thời chỉ ra hạn chế của tập dữ liệu cũ và lợi ích vượt trội khi khai thác vân trong học sâu cho phân đoạn ngữ nghĩa. Vì tập dữ liệu về thực phẩm, tương tự, có đặc trưng kết cấu bề mặt đa dạng, nên kỹ thuật phân tích về vân được áp dụng với hy vọng mang lại hiệu quả tương tự.

Cụ thể, để kiểm tra và xác nhận mức độ tương đồng về kết cấu bề mặt giữa các lớp con trước khi gộp, phương pháp phân tích texture dựa trên ma trận đồng xuất hiện mức xám (Gray-Level Co-occurrence Matrix - GLCM) – một descriptor thống kê kinh điển do Haralick và cộng sự đề xuất – được áp dụng [13]. GLCM mô tả phân bố không gian của các giá trị mức xám trong vùng ảnh, từ đó trích xuất các đặc trưng texture chính: contrast (độ tương phản), homogeneity (độ đồng nhất), energy (năng lượng) và correlation (tương quan). Vector đặc trưng texture trung bình $\mathbf{f}_k$ của mỗi lớp con k được tính từ các patch ảnh thuộc lớp đó. Độ tương đồng giữa hai lớp con i và j được định lượng bằng cosine similarity trên vector đặc trưng này:$\mathrm{Sim}(i, j) = \frac{\mathbf{f}_i \cdot \mathbf{f}_j}{\|\mathbf{f}_i\| \ \|\mathbf{f}_j\|}$

Các lớp con chỉ được gộp khi $\mathrm{Sim}(i, j) \geq 0.85$, đảm bảo tính thống nhất cao về vân và màu sắc bề mặt, từ đó giảm đáng kể mất cân bằng lớp và tăng kích thước mẫu huấn luyện hiệu quả cho từng lớp đích mà vẫn giữ nguyên giá trị ngữ nghĩa cốt lõi.

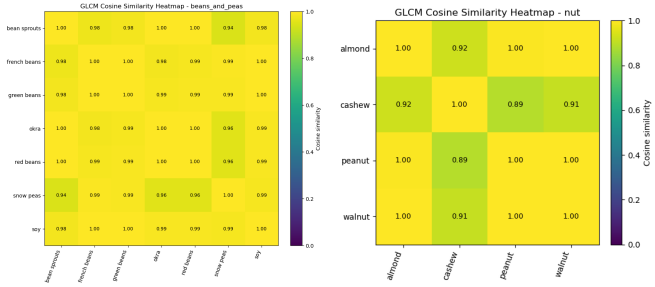

(a) Beans and Peas (b) Nuts

Fig. 2: Ma trận cosine similarity dựa trên đặc trưng GLCM giữa các lớp con.

Quy trình tái cấu trúc dữ liệu trên bộ dữ liệu Food-Seg103 không chỉ giảm độ phân mảnh nhãn mà còn tạo điều kiện cho mô hình học được đặc trưng thị giác vững chắc hơn. Cụ thể, các nhóm lớp được gộp lại khi chúng chia sẻ đặc trưng thống nhất: ví dụ, các loại nấm khác nhau được gộp thành mushroom nhờ cách thức chế biến giống nhau, dẫn đến sự tương đồng cao về màu sắc và vân bề mặt.

TABLE I: Các nhóm lớp được gộp theo ngữ nghĩa và đặc trưng kết cấu bề mặt

Nhóm lớp gốc	Lớp sau khi gộp
king oyster mushroom, oyster mushroom, enoki mushroom, white button mushroom, shiitake	mushroom
green beans, french beans, snow peas, bean sprouts, soy, red beans, okra	beans_and_peas
peanut, almond, cashew, walnut	nut
cake, biscuit, pudding, egg tart, candy, chocolate, popcorn	desserts
lemon, orange	citrus
spring onion, onion, garlic, ginger	alliums_and_garlic
cabbage, rape, lettuce	leafy_greens
kelp, seaweed	seaweed

Các lớp có tần suất rất thấp hoặc không đủ đặc trưng

vân/màu sắc riêng biệt được ánh xạ vào lớp bao quát other ingredients.

Cách tiếp cận này không chỉ giảm số lớp từ 103 xuống còn 75 mà còn tăng đáng kể kích thước mẫu huấn luyện hiệu quả cho từng lớp đích, hạn chế mất mát thông tin so với việc loại bỏ hoàn toàn. Kết quả phân tích texture cho thấy sự gộp dựa trên GLCM và cosine similarity đã tạo ra các lớp đích có tính đồng nhất cao, phù hợp với đặc trưng của thực phẩm thực tế và nâng cao khả năng khái quát hóa của mô hình phân đoạn.

B. Dữ liệu sau xử lý

Không gian nhãn giảm từ 103 xuống 75 lớp, tập dữ liệu mới sẽ được đặt là FoodSeg103_rebalanced. Về số lượng ảnh, tập train giảm từ 3982 xuống 3981 ảnh (giảm 1 ảnh) và tập test giữ nguyên 2135 ảnh. Theo thống kê export trong notebook, ảnh bị loại chủ yếu do lỗi hỏng tệp ảnh (bad image), trong khi số ảnh bị loại do empty mask sau ánh xạ là 0 ở cả hai split.

TABLE II: So sánh dữ liệu trước và sau xử lý

Chỉ số	Trước xử lý	Sau xử lý
Số lớp mục tiêu	103	75
Số ảnh train	3982	3981
Số ảnh test	2135	2135

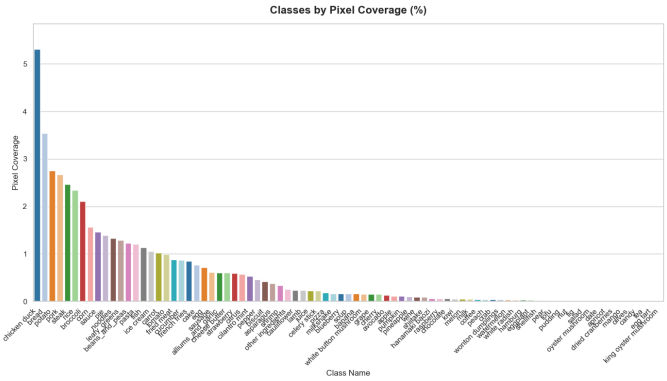

Fig. 3: Mức bao phủ pixel theo lớp sau khi gộp.

Từ góc nhìn huấn luyện, bộ FoodSeg103_rebalanced giúp giảm áp lực học trên các lớp cực hiếm và tăng tính ổn định của tối ưu hóa. Tuy nhiên, long-tail chưa biến mất hoàn toàn, nên các kỹ thuật như focal loss, class-weighted loss, cùng theo dõi per-class IoU vẫn là cần thiết để bảo đảm mô hình không thiên lệch về lớp đa số.

C. Huấn luyện

Trong thiết lập thực nghiệm, tập test của bộ FoodSeg103_rebalanced được giữ nguyên để làm tập đánh giá cuối cùng, gồm 2,135 ảnh. Từ 3,981 ảnh của tập train sau xử lý, dữ liệu được chia tiếp thành tập huấn luyện và tập kiểm định nội bộ theo tỉ lệ 90/10 bằng hàm train_test_split với random_state cố định theo seed của thí nghiệm. Theo cấu hình này, mô hình được huấn luyện trên 3,582 ảnh và được theo dõi trên 399 ảnh validation. Cách chia này giúp tách rõ ba vai trò: train để tối ưu tham số, validation để theo dõi hội tụ và chọn checkpoint, còn test giữ nguyên như tập đánh giá độc lập.

TABLE III: Cấu hình tham số huấn luyện mô hình cơ sở BiSeNet.

Tham số (Hyperparameter)	Giá trị / Thiết lập
Kích thước crop đầu vào (Crop size)	512×512
Kiến trúc mạng xương sống (Backbone)	Xception39
Hàm tối ưu (Optimizer)	SGD (Momentum = 0.9, Weight decay = 1×10^{-4})
Hàm mất mát (Loss function)	Cross-Entropy, auxiliary weight = 1.0
Tốc độ học khởi tạo (Initial LR)	2.5×10^{-2} với chiến lược Poly (power = 0.9)
Kích thước lô (Batch size)	8
Số epoch huấn luyện (Epochs)	150
Tỉ lệ validation (Val ratio)	0.1
Data augmentation scale	$\{0.75, 1.0, 1.5, 1.75, 2.0\}$
Số worker nạp dữ liệu (Num workers)	0
Ignore index	255
Automatic Mixed Precision (AMP)	True
Resume training	True

D. Kết quả

Hình 4 trình bày diễn biến hàm mất mát trong quá trình huấn luyện BiSeNet trên toàn bộ tập train của bộ FoodSeg103_rebalanced, với tập validation được tách nội bộ từ tập huấn luyện theo tỉ lệ 10%. Đường cong cho thấy loss huấn luyện giảm dần theo epoch, trong khi loss kiểm định có giai đoạn dao động mạnh ở khoảng giữa quá trình học trước khi ổn định trở lại. Quan sát này phù hợp với đặc tính long-tail và độ khó cao của dữ liệu thực phẩm fine-grained, đồng thời cho thấy việc theo dõi validation loss là cần thiết để chọn checkpoint phù hợp thay vì chỉ dựa trên train loss.

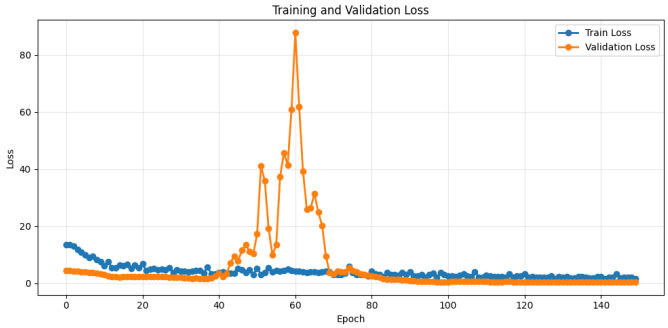

Fig. 4: Diễn biến train loss và validation loss trong quá trình huấn luyện BiSeNet trên tập train của FoodSeg103_rebalanced.

Hình 5 minh họa một số kết quả dự đoán của mô hình cơ sở trên tập kiểm định. Nhìn chung, BiSeNet có thể tái tạo tương đối tốt cấu trúc tổng thể của món ăn và nhận diện được các vùng nguyên liệu lớn, nhưng vẫn xuất hiện sai lệch ở các vùng biên mỏng hoặc các thành phần có texture gần nhau. Một ví dụ lỗi điển hình được trình bày ở Hình 6, trong đó mô hình dự đoán sai đáng kể ở các vùng nguyên liệu chồng lấp và có màu sắc tương tự.

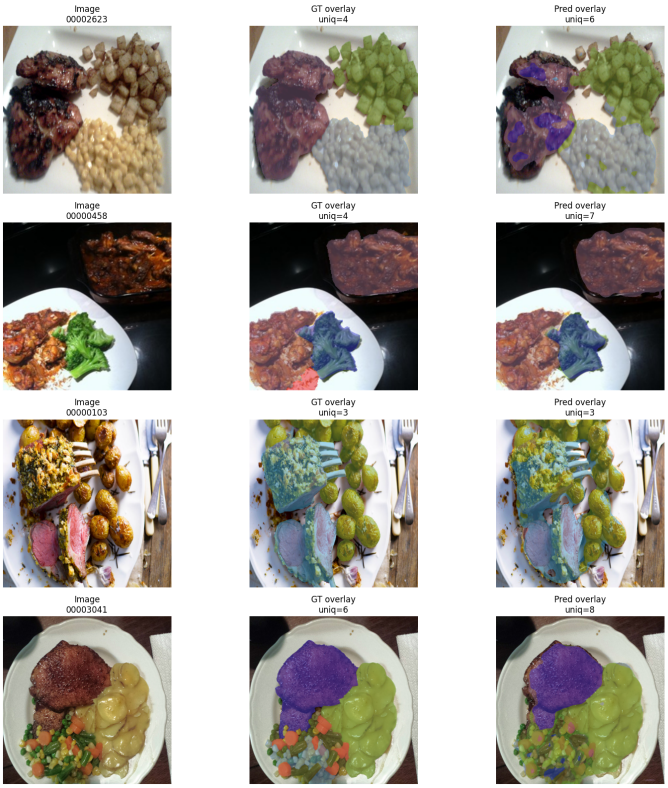

Fig. 5: Một số ví dụ dự đoán của BiSeNet trên tập kiểm định, gồm ảnh gốc, ground truth overlay và prediction overlay.

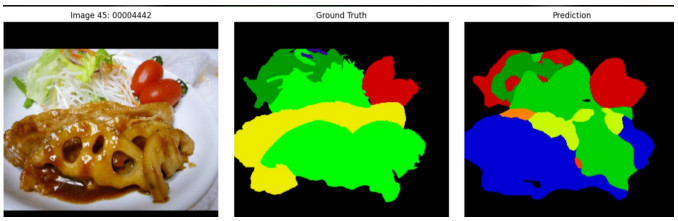

Fig. 6: Ví dụ lỗi dự đoán điển hình của BiSeNet khi các thành phần nguyên liệu có ranh giới mờ hoặc chồng lấp mạnh.

TABLE IV: Các chỉ số đánh giá của mô hình cơ sở BiSeNet trên tập kiểm định của bộ dữ liệu FoodSeg103.

Chỉ số	Giá trị
aAcc	0.8502
$\text{mIoU}_{\text{present}}$	0.6354
$\text{mIoU}_{\text{fg,present}}$	0.5828
$\text{mAcc}_{\text{present}}$	0.7397
$\text{mAcc}_{\text{fg,present}}$	0.6992

Theo tiêu chí đã định nghĩa ở phần trước, mIoU là chỉ số đánh giá chính vì phản ánh trực tiếp mức giao nhau trên hợp giữa mask dự đoán và ground truth ở cấp độ pixel. Trên các lớp thực sự xuất hiện trong tập đánh giá, baseline BiSeNet đạt $\text{mIoU}_{\text{present}} = 0.6354$. Khi chỉ xét các lớp foreground xuất hiện và loại bỏ ảnh hưởng của nền, kết quả giảm xuống còn $\text{mIoU}_{\text{fg,present}} = 0.5828$, cho thấy bài toán phân đoạn nguyên liệu vẫn khó đáng kể ở những vùng mang tính fine-grained.

Các chỉ số bổ sung cũng cho thấy cùng một xu hướng. Mô hình đạt $\text{mAcc}_{\text{present}} = 0.7397$ và $\text{mAcc}_{\text{fg,present}} = 0.6992$, tức là khả năng nhận diện đúng theo lớp ở mức chấp nhận được nhưng vẫn suy giảm khi chỉ xét riêng các lớp nguyên liệu foreground. Trong khi đó, $\text{aAcc} = 0.8502$ tương đối cao, phản ánh rằng mô hình dự đoán đúng trên phần lớn pixel toàn cục. Tuy nhiên, do overall accuracy dễ bị chi phối bởi các vùng lớn hoặc dễ phân đoạn, chỉ số này không đủ để thay thế mIoU trong bối cảnh dữ liệu mất cân bằng lớp và có nhiều vùng biên phức tạp như FoodSeg103.

Kết hợp giữa định lượng và quan sát trực quan, có thể thấy baseline BiSeNet đã học được cấu trúc tổng thể của món ăn và các vùng nguyên liệu lớn, nhưng vẫn gặp khó ở các thành phần có diện tích nhỏ, biên yếu hoặc texture gần nhau. Điều này phù hợp với giả thuyết của nghiên cứu: một kiến trúc lightweight có thể tạo mốc hiệu năng hữu ích, nhưng để cải thiện thêm trên bài toán ingredient-level fine-grained thì cần các cơ chế tăng cường local detail, texture hoặc boundary-aware ở các bước tiếp theo.

V. Kết luận

Báo cáo này tập trung vào bước nền cho bài toán phân đoạn nguyên liệu thực phẩm fine-grained trên FoodSeg103 thông qua hai hướng chính: tái cấu trúc dữ liệu để giảm tác động của long-tail imbalance và chuẩn hóa baseline BiSeNet trên bộ dữ liệu sau xử lý. Kết quả thực nghiệm cho thấy hướng tiếp cận này đủ để thiết lập một mốc tham chiếu rõ ràng cho bài toán, đồng thời cũng làm lộ ra những hạn chế đặc trưng của mô hình lightweight khi phải xử lý các vùng biên yếu, vùng chồng lấp và các lớp nguyên liệu có texture gần nhau. Trên cơ sở đó, bước tiếp theo của nghiên cứu không còn là hoàn thiện pipeline cơ sở, mà là kiểm tra có hệ thống xem các mô-đun nhạy với texture, local detail hoặc boundary-aware có thể cải thiện chất lượng phân đoạn đến mức nào trên cùng thiết lập thực nghiệm. Mã nguồn thực nghiệm được công bố tại https://github.com/ariesanhthu/PROJECT-CV.

References

[1] J. Long, E. Shelhamer, and T. Darrell, “Fully convolutional networks for semantic segmentation,” in Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR), 2015, pp. 3431–3440.

[2] L.-C. Chen, G. Papandreou, F. Schroff, and H. Adam, “Rethinking atrous convolution for semantic image segmentation,” 2017, arXiv:1706.05587. [Online]. Available: https://arxiv.org/abs/1706.05587

[3] C. Yu, J. Wang, C. Peng, C. Gao, G. Yu, and N. Sang, “BiSeNet: Bilateral segmentation network for real-time semantic segmentation,” in Proc. European Conf. Computer Vision (ECCV), 2018, pp. 325–341.

[4] A. Paszke, A. Chaurasia, S. Kim, and E. Culurciello, “ENet: A deep neural network architecture for real-time semantic segmentation,” 2016, arXiv:1606.02147. [Online]. Available: https://arxiv.org/abs/1606.02147

[5] Z. Huang, X. Wang, Y. Wei, L. Huang, H. Shi, W. Liu, and T. S. Huang, "CCNet: Criss-cross attention for semantic segmentation," 2018, arXiv:1811.11721. [Online]. Available: https://arxiv.org/abs/1811.11721

[6] X. Wu, X. Fu, Y. Liu, E.-P. Lim, S. C. H. Hoi, and Q. Sun, "A large-scale benchmark for food image segmentation," 2021, arXiv:2105.05409. [Online]. Available: https://arxiv.org/abs/2105.05409

[7] N. P. Mahalik and A. N. Nambiar, "Trends in food packaging and manufacturing systems and technology," Trends in Food Science & Technology, vol. 21, no. 3, pp. 117–128, 2010.

[8] Stemmer Imaging, "Vision technology for the food and beverage industry," Stemmer Imaging Market Brochure, 2018.

[9] X. Gao et al., "Research on food recognition of smart refrigerator based on SSD target detection algorithm," in Proc. Int. Conf. Artificial Intelligence and Computer Science, 2019, pp. 303–308.

[10] K. Wang et al., "A smart refrigerator architecture that reduces food ingredients waste materials and energy consumption," Ekoloji Dergisi, no. 107, 2019.

[11] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR), 2016, pp. 770–778.

[12] K. Dong, C. Zhou, Y. Ruan, and Y. Li, "MobileNetV2 model for image classification," in Proc. 2nd Int. Conf. Information Technology and Computer Application (ITCA), 2020, pp. 476–480.

[13] R. M. Haralick, K. Shanmugam, and I. H. Dinstein, "Textural features for image classification," IEEE Trans. Systems, Man, and Cybernetics, vol. SMC-3, no. 6, pp. 610–621, Nov. 1973.

[14] Z. Zheng, Y. Zhong, T. Wang, and J. Chen, "Rethinking semantic segmentation from a sequence-to-sequence perspective with transformers," in Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), 2021, pp. 6881–6890.

[15] H. Zhao, J. Shi, X. Qi, X. Wang, and J. Jia, "Pyramid scene parsing network," in Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR), 2017, pp. 2881–2890.

[16] R. P. K. Poudel, S. Liwicki, and R. Cipolla, "Fast-SCNN: Fast semantic segmentation network," in Proc. British Machine Vision Conf. (BMVC), 2019, pp. 1–14.

[17] T. Takikawa, D. Acuna, V. Jampani, and S. Fidler, "Gated-SCNN: Gated shape CNNs for semantic segmentation," in Proc. IEEE/CVF Int. Conf. Computer Vision (ICCV), 2019, pp. 5229–5238.

[18] A. Kirillov, Y. Wu, K. He, and R. Girshick, "PointRend: Image segmentation as rendering," in Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), 2020, pp. 9799–9808.

[19] H. Zhang, J. Xue, and K. Dana, "Deep TEN: Texture encoding network," in Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR), 2017, pp. 708–717.

[20] J. Xu, Z. Xiong, and S. Bhattacharyya, "PIDNet: A real-time semantic segmentation network inspired by PID controllers," in Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), 2023, pp. 19529–19539.

[21] N. P. Mahalik and A. N. Nambiar, "Trends in food packaging and manufacturing systems and technology," Trends in Food Science & Technology, vol. 21, no. 3, pp. 117–128, 2010.

[22] Stemmer Imaging, "Vision technology for the food and beverage industry," Stemmer Imaging Market Brochure, 2018.

[23] X. Gao et al., "Research on food recognition of smart refrigerator based on SSD target detection algorithm," in Proc. Int. Conf. Artificial Intelligence and Computer Science, 2019, pp. 303–308.

[24] K. Wang et al., "A smart refrigerator architecture that reduces food ingredients waste materials and energy consumption," Ekoloji Dergisi, no. 107, 2019.

[25] F. Zhuang et al., "A comprehensive survey on transfer learning," Proc. IEEE, vol. 109, no. 1, pp. 43–76, 2021.

[26] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," arXiv preprint arXiv:1512.03385, 2015.

[27] K. Dong, C. Zhou, Y. Ruan, and Y. Li, "MobileNetV2 model for image classification," in Proc. 2nd Int. Conf. Information Technology and Computer Application (ITCA), 2020, pp. 476–480.