fit@hcmus

Trường Đại học Khoa học tự nhiên, ĐHQG-HCM
Khoa Công nghệ Thông tin

# Dimension Reduction, Linear Classification and Non-linear Learning Algorithms

Nhóm thực hiện

TP. Hồ Chí Minh, 19/03/2026

# Mục lục


1. Tổng quan
2. Dimension Reduction
3. Linear Classification
4. Non-linear Learning Algorithms
5. Kết luận

# Mục lục


1. Tổng quan
2. Dimension Reduction
3. Linear Classification
4. Non-linear Learning Algorithms
5. Kết luận

# Bối cảnh

Trong nhiều bài toán học máy, dữ liệu đầu vào thường có số chiều rất lớn: mỗi mẫu được mô tả bởi rất nhiều biến số, đặc trưng hoặc tín hiệu đo đạc.

**Ví dụ điển hình**

- Ảnh số có hàng trăm đến hàng nghìn pixel hoặc đặc trưng.
- Dữ liệu y sinh chứa nhiều chỉ số định lượng.
- Dữ liệu cảm biến và hành vi có nhiều biến theo thời gian.
- Dữ liệu văn bản có không gian đặc trưng rất lớn.

**Ba khó khăn chính**

- Khoảng cách giữa các điểm dữ liệu trở nên kém trực quan và kém phân biệt.
- Mô hình có nhiều tham số hơn, dễ quá khớp.
- Chi phí tính toán và lưu trữ tăng mạnh.

**Tóm lại:** hiện tượng này thường được gọi là **curse of dimensionality**.

# Ba câu hỏi trung tâm của bài thuyết trình

Từ bối cảnh trên, bài thuyết trình xoay quanh ba câu hỏi:

1. Có thể rút gọn dữ liệu về không gian thấp chiều hơn mà vẫn giữ lại thông tin quan trọng hay không?
2. Nếu dữ liệu có thể được phân tách gần tuyến tính, liệu các mô hình đơn giản có đủ hiệu quả không?
3. Nếu cấu trúc dữ liệu hoặc biên quyết định là phi tuyến, ta cần mở rộng mô hình như thế nào?

**Ba câu hỏi này dẫn trực tiếp tới ba nhóm phương pháp: Dimension Reduction**, **Linear Classification** và **Non-linear Learning Algorithms**.

# Mapping ba chủ đề trong pipeline học máy

| Chủ đề | Vai trò | Đầu ra chính | Câu hỏi trọng tâm |
|---|---|---|---|
| Dimension Reduction | Nén thông tin, trực quan hóa, khử nhiễu | Biểu diễn thấp chiều $z \in \mathbb{R}^K$ | Dữ liệu thực sự sống trong không gian nào? |
| Linear Classification | Dự đoán nhãn bằng siêu phẳng | Nhãn dự đoán hoặc xác suất lớp | Có thể tách lớp bằng một ranh giới tuyến tính không? |
| Non-linear Learning Algorithms | Mô hình hóa biên quyết định phức tạp | Quy tắc quyết định phi tuyến | Nếu siêu phẳng không đủ, cần mô hình mạnh hơn nào? |

## Pipeline

Dữ liệu gốc $x \in \mathbb{R}^D$ → **Dimension Reduction** → biểu diễn gọn hơn → **Linear / Non-linear Classification** → dự đoán $\hat{y}$

**Ý chính:** giảm chiều giúp tạo biểu diễn tốt hơn; phân loại tuyến tính là mốc đơn giản, dễ diễn giải; học phi tuyến mở rộng năng lực mô hình khi dữ liệu phức tạp hơn.

Nguồn chính: Duchesnay et al., 2021

# Mục lục


1 Tổng quan

2 Dimension Reduction

3 Linear Classification

4 Non-linear Learning Algorithms

5 Kết luận

# Dimension Reduction: mục đích và phát biểu bài toán

## Mục đích

- Giảm số chiều $P \to K$ với $K \ll P$ để trực quan hóa và tăng tốc tính toán.
- Loại bỏ nhiễu, đa cộng tuyến và đặc trưng dư thừa.
- Tạo biểu diễn mới thuận lợi hơn cho mô hình downstream.

## Phát biểu bài toán

Với dữ liệu $X \in \mathbb{R}^{N \times P}$, tìm ánh xạ

$$f : \mathbb{R}^P \to \mathbb{R}^K, \qquad z_i = f(x_i)$$

sao cho biểu diễn mới vẫn giữ được cấu trúc quan trọng của dữ liệu.

## Hai họ phương pháp

- **Tuyến tính**: PCA, SVD.
- **Phi tuyến**: MDS, Isomap, t-SNE.

$x \in \mathbb{R}^P$
Không gian gốc

↓

$f(\cdot)$
Phép biến đổi

↓

$z \in \mathbb{R}^K$
Không gian thấp chiều

## Ý nghĩa thực tế

Giảm chiều không chỉ để "nén" dữ liệu; trong học máy, đây là bước **trích xuất đặc trưng** giúp mô hình học trên tín hiệu ổn định hơn.

# PCA: phương pháp giải cho giảm chiều tuyến tính

## Bước 1. Tiền xử lý

- Center dữ liệu: $X_c = X - 1\bar{x}^\top$.
- Chuẩn hóa nếu các biến có thang đo rất khác nhau.

## Bước 2. Tìm trục phương sai lớn nhất

$$S_{XX} = \frac{1}{N-1} X_c^\top X_c$$

$$v_1 = \arg\max_{\|v\|=1} v^\top S_{XX} v$$

Các trục tiếp theo là các vector riêng trực giao ứng với trị riêng lớn nhất còn lại.

## Bước 3. Chiếu dữ liệu

$$V_K = [v_1, \ldots, v_K], \qquad C = X_c V_K$$

Trong thực hành, PCA thường được tính bằng **SVD** vì ổn định và không cần tạo trực tiếp ma trận hiệp phương sai.

## Đầu ra của PCA

- **Loadings**: hướng của các thành phần chính.
- **Scores**: tọa độ mới của từng mẫu.
- **Explained variance**: mức phương sai được giữ lại trên từng trục.

## Kiểm chứng tính đúng đắn

Chọn $K^\star$ sao cho

$$\frac{\sum_{k=1}^{K^\star} \lambda_k}{\sum_{k=1}^{P} \lambda_k}$$

vượt một ngưỡng như 90% hoặc 95%.

PCA theo Duchesnay et al., 2021

# PCA: ý nghĩa hình học và cách diễn giải

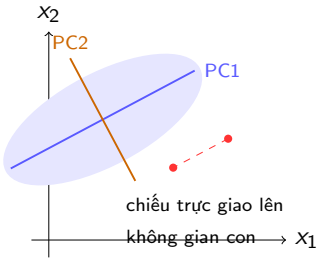


## Ý nghĩa hình học

- PCA quay hệ trục tọa độ về các hướng mà dữ liệu biến thiên mạnh nhất.
- PC1 là trục dài nhất của "ellipsoid dữ liệu".
- Các PC trực giao nên tránh trùng lặp thông tin.

## Cách diễn giải

- Hệ số loading lớn $\Rightarrow$ biến gốc đóng góp mạnh vào thành phần chính.
- Score gần nhau $\Rightarrow$ mẫu có cấu trúc tương tự nhau trong biểu diễn mới.
- Nếu chỉ vài PC đầu đã giữ gần hết phương sai, dữ liệu có cấu trúc gần tuyến tính.

# PCA: ví dụ và kiểm chứng trên dữ liệu thực nghiệm

## Ví dụ 1: dữ liệu 2 biến tương quan mạnh

Trong ví dụ "experience–salary" của tài liệu, PCA cho:

$$\text{EVR} = [0.936,\ 0.064]$$

- PC1 giữ khoảng **93.6%** phương sai.
- Dữ liệu gần như nằm trên một đường thẳng trong không gian 2D.
- Kết luận: chỉ cần 1 thành phần chính là đã giữ lại phần lớn thông tin.

## Ví dụ 2: Eigenfaces

Với bộ ảnh khuôn mặt Olivetti:

- PCA trích ra các **mẫu biến thiên chính** của mắt, mũi, miệng, ánh sáng.
- Mỗi ảnh được biểu diễn bởi một vector hệ số thấp chiều thay vì toàn bộ pixel.
- Biểu diễn này có thể đưa tiếp vào bộ phân lớp như SVM.

## Tiêu chí kiểm chứng

- Tỷ lệ phương sai tích lũy.
- Chất lượng tái tạo hoặc hiệu năng mô hình downstream.
- Khả năng trực quan hóa tách cụm sau khi chiếu.

Ví dụ từ Duchesnay et al., 2021

# Giảm chiều phi tuyến: khi nào PCA không còn đủ?

## Mục đích

Khi dữ liệu nằm trên một **đa tạp thấp chiều nhưng cong**, ta muốn "trải phẳng" cấu trúc đó mà vẫn giữ quan hệ lân cận hoặc khoảng cách nội tại.

## Phát biểu bài toán

Tìm embedding $Z \in \mathbb{R}^{N \times K}$ sao cho:

- khoảng cách cặp điểm được bảo toàn càng tốt càng tốt; hoặc
- lân cận địa phương được bảo toàn; hoặc
- topology của manifold không bị phá vỡ.

## Giả thuyết manifold

Dữ liệu quan sát trong không gian cao chiều thực ra có thể tập trung gần một cấu trúc nội tại thấp chiều hơn rất nhiều.

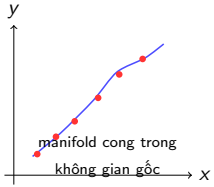


## Hệ quả

Khoảng cách Euclid ngắn chưa chắc phản ánh đúng **khoảng cách geodesic** dọc theo manifold.

Tổng quan theo Duchesnay et al., 2021; Tenenbaum et al., 2000

# MDS, Isomap, t-SNE: phương pháp và ý nghĩa hình học

| Phương pháp | Phương pháp giải | Ý nghĩa hình học | Khi nên dùng |
|---|---|---|---|
| MDS | Tối thiểu hóa *stress* $\sum_{i \neq j} \left(d_{ij} - \lVert z_i - z_j \rVert\right)^2$ | Bảo toàn khoảng cách cặp điểm càng sát càng tốt. Nếu $D$ là khoảng cách Euclid và double-centering phù hợp, kết quả tương đương PCA. | Khi ta có ma trận khoảng cách hoặc độ bất tương tự. |
| Isomap | 1) Chọn lân cận. 2) Dựng đồ thị. 3) Tính shortest path như xấp xỉ geodesic. 4) Chạy MDS trên ma trận geodesic. | "Trải phẳng" manifold trong khi giữ khoảng cách nội tại dọc bề mặt. | Khi dữ liệu có một manifold liên tục như Swiss roll, S-curve. |
| t-SNE | Khớp hai phân phối xác suất lân cận trong không gian gốc và không gian thấp chiều bằng cách tối thiểu hóa KL divergence. | Nhấn mạnh **cấu trúc cục bộ**; tách các cụm tốt nhưng không mạnh về khoảng cách toàn cục. | Khi mục tiêu là trực quan hóa cụm và lân cận của dữ liệu cao chiều. |

**Lưu ý kiểm chứng**

MDS dùng **stress**, Isomap kiểm tra khả năng mở manifold, còn t-SNE nên đánh giá bằng chất lượng lân cận và trực quan, không nên suy diễn khoảng cách toàn cục quá mạnh.

Duchesnay et al., 2021; Tenenbaum et al., 2000; van der Maaten and Hinton, 2008

# Ví dụ giảm chiều phi tuyến và cách chọn phương pháp

## Ví dụ trong sách

- **MDS**: khôi phục tọa độ các thành phố châu Âu từ ma trận khoảng cách đường bộ.
- **Isomap**: mở dữ liệu dạng *S-curve*/*Swiss roll* thành mặt phẳng 2D.
- **t-SNE**: tạo các cụm trực quan rõ ràng trên dữ liệu cao chiều như chữ số viết tay.

## Cách kiểm chứng tính đúng đắn

- So sánh embedding với cấu trúc gốc nếu có dữ liệu giả lập.
- Đo stress hoặc neighborhood preservation.
- Kiểm tra embedding có phục vụ tốt cho trực quan hóa và khám phá dữ liệu hay không.

## Nguyên tắc chọn

- **PCA**: cần diễn giải, ổn định, nhanh.
- **MDS**: khi đầu vào là ma trận khoảng cách.
- **Isomap**: muốn bảo toàn cấu trúc manifold liên tục.
- **t-SNE**: ưu tiên trực quan hóa cụm địa phương.

## Kết luận ngắn

Giảm chiều tuyến tính và phi tuyến là hai công cụ **bổ sung** cho nhau: PCA mạnh về diễn giải và tiền xử lý, trong khi manifold learning mạnh về khám phá cấu trúc cong

# Mục lục


1 Tổng quan

2 Dimension Reduction

3 Linear Classification

4 Non-linear Learning Algorithms

5 Kết luận

# Linear Classification: mục đích và phát biểu bài toán

## Mục đích

Học một quy tắc quyết định đơn giản, diễn giải được, để gán nhãn cho mẫu đầu vào:

$$\hat{y} = 1\{w^\top x + b > 0\}$$

hoặc dự đoán xác suất hậu nghiệm của lớp.

## Phát biểu bài toán

Cho tập huấn luyện

$$\mathscr{D} = \{(x_i, y_i)\}_{i=1}^N, \quad x_i \in \mathbb{R}^P, \; y_i \in \{0, 1\}$$

tìm vector tham số $w$ và bias $b$ sao cho siêu phẳng

$$w^\top x + b = 0$$

phân tách tốt nhất các lớp.

## Ý nghĩa hình học

- $w$ xác định hướng phân biệt.
- Mỗi điểm được chiếu lên trục $w$.
- Ngưỡng trên trục đó quyết định nhãn dự đoán.

## Khi phù hợp

- Số chiều cao nhưng dữ liệu khá "phẳng".
- Cần mô hình nhanh, ổn định, dễ giải thích.
- Cần baseline mạnh trước khi dùng mô hình phi tuyến.

Khung bài toán theo Duchesnay et al., 2021

# Fisher và LDA: từ tiêu chuẩn hình học đến mô hình xác suất

## Fisher Linear Discriminant

Chọn hướng $w$ làm cực đại tỉ số:

$$J(w) = \frac{w^\top S_B w}{w^\top S_W w}$$

- Tử số: khoảng cách giữa tâm các lớp sau khi chiếu.
- Mẫu số: độ phân tán trong từng lớp sau khi chiếu.
- Mục tiêu: lớp xa nhau nhất nhưng từng lớp vẫn "gọn".

## Ý nghĩa hình học

Fisher không bắt đầu từ xác suất; nó tìm **trục chiếu phân biệt nhất** trong không gian đặc trưng.

## Linear Discriminant Analysis (LDA)

LDA là bản xác suất của Fisher:

$$x \mid C_k \sim \mathcal{N}(\mu_k, S_W)$$

- Ước lượng phân phối có điều kiện của từng lớp.
- Dùng Bayes để tính $p(C_k \mid x)$.
- Phân lớp theo nguyên lý MAP.

## Kiểm chứng tính đúng đắn

- Kiểm tra giả định hiệp phương sai chung.
- Đánh giá trên tập kiểm tra bằng lỗi phân lớp, bACC, AUC.
- LDA đặc biệt hữu ích khi cần xử lý prior khác nhau ở dữ liệu mất cân bằng.

Duchesnay et al., 2021; Fisher, 1936

# Logistic Regression: mô hình trực tiếp cho xác suất hậu nghiệm

## Phương pháp

Logistic regression mô hình hóa trực tiếp:

$$p(y=1 \mid x) = \sigma(w^\top x + b) = \frac{1}{1+e^{-(w^\top x+b)}}$$

và ước lượng tham số bằng cách tối thiểu hóa **logistic loss**/cross-entropy.

## Vì sao hiệu quả?

- Là mô hình **discriminative**: chỉ học biên quyết định.
- Số tham số ít hơn LDA khi số chiều lớn.
- Có thể diễn giải dấu và độ lớn của hệ số $w_j$.

## Regularization

- **L2 / Ridge**: co nhỏ hệ số, giảm overfitting.
- **L1 / Lasso**: vừa regularize vừa chọn đặc trưng.
- **Elastic-net**: cân bằng giữa ổn định và sparsity.

## Ý nghĩa hình học

Sigmoid là phi tuyến, nhưng **mặt quyết định** vẫn là siêu phẳng:

$$w^\top x + b = 0$$

Duchesnay et al., 2021

# Linear SVM: tối đa biên để tăng độ vững

## Bài toán tối ưu

Với mã nhãn $y_i \in \{-1, +1\}$, Linear SVM giải:

$$\min_{w,b} \frac{1}{2}\|w\|_2^2 + C\sum_{i=1}^{N} \max\big(0, 1 - y_i(w^\top x_i + b)\big)$$

- Hinge loss phạt mạnh các điểm nằm sai phía hoặc nằm trong biên.
- $C$ điều khiển đánh đổi giữa **biên lớn** và **số lỗi huấn luyện**.

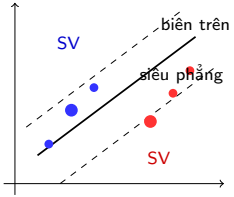


## Ý nghĩa hình học

Chỉ các **support vectors** mới quyết định biên phân lớp.

## Quan hệ với logistic regression

Cùng học siêu phẳng tuyến tính, nhưng logistic tối ưu xác suất còn SVM tối ưu **margin**.

Cortes and Vapnik, 1995; Duchesnay et al., 2021

# Kiểm chứng tính đúng đắn và ví dụ cho phân loại tuyến tính

## Các chỉ số cần báo cáo

- Accuracy: độ chính xác tổng thể.
- Sensitivity và Specificity: đặc biệt quan trọng khi dữ liệu mất cân bằng.
- Balanced Accuracy:

$$\text{bACC} = \frac{\text{SEN} + \text{SPC}}{2}$$

- ROC-AUC: đo chất lượng tách lớp độc lập với ngưỡng.

## Dữ liệu mất cân bằng

Với logistic regression hoặc SVM, có thể dùng `class_weight="balanced"` hoặc tái lấy mẫu để tránh thiên lệch về lớp đa số.

## Ví dụ trong sách

Trên dữ liệu 2 lớp Gaussian 2 chiều:

- **LDA**: 10/200 mẫu bị phân sai $\Rightarrow$ lỗi 5%.
- **Logistic regression**: cũng cho lỗi 5%.

Điều này cho thấy khi giả định tuyến tính phù hợp, các mô hình tuyến tính vừa đơn giản vừa rất cạnh tranh.

## Kết luận chọn mô hình

- **Fisher/LDA**: mạnh khi muốn gắn với giả định phân phối và prior lớp.
- **Logistic**: mạnh khi cần xác suất hậu nghiệm.
- **Linear SVM**: mạnh khi ưu tiên margin và độ vững.

Duchesnay et al., 2021

# Mục lục


1 Tổng quan

2 Dimension Reduction

3 Linear Classification

4 Non-linear Learning Algorithms

5 Kết luận

# Non-linear Learning: mục đích và phát biểu bài toán

## Động cơ

Trong nhiều bài toán, các lớp không thể tách bằng một siêu phẳng duy nhất:

- biên quyết định cong;
- tương tác biến phức tạp;
- cấu trúc phân vùng nhiều mức.

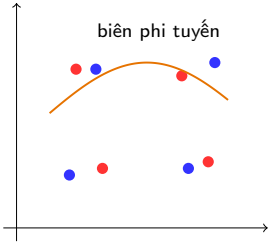


## Phát biểu bài toán

Tìm một hàm quyết định phi tuyến

$$f(x) : \mathbb{R}^P \to \{0, 1, \ldots, C-1\}$$

đủ linh hoạt để mô hình hóa quan hệ phức tạp nhưng vẫn tổng quát hóa tốt ngoài mẫu.

## Ý nghĩa

Mô hình phi tuyến thường mạnh hơn, nhưng phải kiểm soát kỹ **độ phức tạp** để tránh overfitting.

# Kernel SVM: biến bài toán phi tuyến thành tuyến tính trong không gian đặc trưng

## Ý tưởng cốt lõi

Thay vì làm việc trực tiếp trong không gian gốc, SVM dùng kernel

$$K(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle$$

để ngầm ánh xạ dữ liệu sang không gian đặc trưng nơi bài toán trở nên tuyến tính.

## Kernel RBF

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$$

- $\gamma$ điều khiển "độ rộng" của vùng ảnh hưởng.
- $C$ điều khiển mức phạt lỗi huấn luyện.

## Ý nghĩa hình học

- Tuyến tính trong *feature space*.
- Phi tuyến trong không gian gốc.
- Chỉ một số support vectors đóng góp vào hàm quyết định.

## Kiểm chứng tính đúng đắn

- Chuẩn hóa biến đầu vào trước khi huấn luyện.
- Chọn $(C, \gamma)$ bằng cross-validation.
- Đánh giá bằng bACC, ROC-AUC trên tập kiểm tra.

Cortes and Vapnik, 1995; Duchesnay et al., 2021

# Decision Tree, Random Forest, Gradient Boosting

## Decision Tree → Random Forest

- Cây quyết định chia dữ liệu đệ quy theo các phép kiểm tra trên đặc trưng.
- Dễ hiểu nhưng dễ overfit.
- Random Forest khắc phục bằng:
  - huấn luyện nhiều cây;
  - bootstrap mẫu;
  - chọn ngẫu nhiên tập đặc trưng ở mỗi nút.

## Gradient Boosting

- Học **chuỗi** các mô hình yếu.
- Mỗi mô hình mới sửa phần dư/sai số của mô hình trước.
- Hai siêu tham số trọng yếu:
  - **learning rate**: nhỏ hơn thì regularize mạnh hơn;
  - **subsample**: nhỏ hơn 1 tạo stochastic boosting, giảm phương sai.

## Ý nghĩa hình học

Mỗi cây tạo một phân hoạch từng vùng chữ nhật trong không gian đặc trưng; rừng ngẫu nhiên lấy trung bình để làm mượt biên.

## Diễn giải

Boosting thường cho hiệu năng rất mạnh, nhưng khó diễn giải hơn Random Forest và nhạy hơn với tuning.

Breiman, 2001; Duchesnay et al., 2021; Friedman, 2001

# Kiểm chứng tính đúng đắn: so sánh thực nghiệm trong tài liệu

## Thiết lập ví dụ

Tài liệu dùng bộ **Breast Cancer Wisconsin**:

- chia train/test theo tỉ lệ 50/50;
- SVM được chuẩn hóa dữ liệu đầu vào;
- đánh giá bằng **balanced accuracy** và **ROC-AUC**.

## Vì sao các chỉ số này phù hợp?

- bACC cân bằng recall của hai lớp.
- AUC phản ánh chất lượng tách lớp ngay cả khi ngưỡng quyết định chưa tối ưu.

| Mô hình | bACC | AUC |
|---|---|---|
| RBF SVM | 0.97 | 0.99 |
| Random Forest | 0.93 | 0.98 |
| Gradient Boosting | 0.94 | 0.98 |

## Nhận xét

- SVM đạt kết quả tốt nhất trong ví dụ này.
- RF và GB vẫn rất cạnh tranh và ít phụ thuộc giả định hình học rõ ràng.

Kết quả từ Duchesnay et al., 2021

# Ví dụ và nguyên tắc chọn mô hình phi tuyến

| Mô hình | Điểm mạnh | Điểm cần lưu ý | Khi nên ưu tiên |
|---|---|---|---|
| Kernel SVM | Biên quyết định mạnh, hiệu quả trên dữ liệu vừa và ranh giới cong. | Nhạy với scaling và tuning $C, \gamma$; khó diễn giải. | Khi số mẫu vừa phải, số chiều cao, cần biên phân lớp sắc nét. |
| Random Forest | Ít cần tiền xử lý, bền vững, có feature importance. | Dự đoán là tổ hợp nhiều cây nên khó giải thích chi tiết từng quyết định. | Khi muốn baseline mạnh, ổn định và làm việc tốt với tương tác phi tuyến. |
| Gradient Boosting | Thường đạt hiệu năng rất cao, tối ưu sai số theo từng bước. | Dễ overfit nếu learning rate lớn hoặc số cây quá nhiều. | Khi chấp nhận tuning kỹ để lấy hiệu năng tối đa. |

## Thông điệp

Học phi tuyến không thay thế hoàn toàn mô hình tuyến tính; nó được dùng khi dữ liệu cho thấy **ranh giới cong, tương tác phức tạp** hoặc **cấu trúc phân hoạch nhiều mức**.

# Mục lục


1 Tổng quan

2 Dimension Reduction

3 Linear Classification

4 Non-linear Learning Algorithms

5 Kết luận

# Kết luận

## Ba thông điệp cần chốt khi thuyết trình

1. **Dimension reduction** giúp nhìn đúng cấu trúc dữ liệu: PCA mạnh về diễn giải, còn MDS/Isomap/t-SNE mạnh về manifold và trực quan hóa.
2. **Linear classification** là baseline rất mạnh: Fisher/LDA, logistic regression và linear SVM đều dựa trên ý tưởng chiếu dữ liệu lên một trục phân biệt.
3. **Non-linear learning** mở rộng sức biểu diễn của mô hình: kernel SVM, Random Forest, Gradient Boosting phù hợp khi biên quyết định không còn tuyến tính.

## Nguyên tắc chọn mô hình

Bắt đầu từ cấu trúc hình học của dữ liệu, sau đó kiểm chứng bằng **cross-validation**, **balanced accuracy**, **ROC-AUC** và khả năng tổng quát hóa trên tập ngoài mẫu.

Tài liệu nền tảng: Duchesnay et al., 2021

# Tài liệu tham khảo


Breiman, L. (2001).Random forests. *Machine Learning*, *45*(1), 5–32.

Cortes, C., & Vapnik, V. (1995).Support-vector networks. *Machine Learning*, *20*(3), 273–297.

Duchesnay, E., Lofstedt, T., & Younes, F. (2021). *Statistics and machine learning in python* (0.5). Online book.

Fisher, R. A. (1936).The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, *7*(2), 179–188.

Friedman, J. H. (2001).Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, *29*(5), 1189–1232.

Tenenbaum, J. B., de Silva, V., & Langford, J. C. (2000).A global geometric framework for nonlinear dimensionality reduction. *Science*, *290*(5500), 2319–2323.

van der Maaten, L., & Hinton, G. (2008).Visualizing data using t-sne. *Journal of Machine Learning Research*, *9*, 2579–2605.

# Key question

# Cảm ơn thầy, cô và các bạn đã chú ý lắng nghe!